

02-企业专用模型训练调优与机载嵌入式部署专项研究报告 (v1.2)

文档信息	
编号	02
版本	v1.2 (定稿方向·已并入指标收口默认值, 与 11-v1.4 对齐)
日期	2026-09-08
来源	01 号研究报告 + 11 号建设方案建议的延伸论证 (企业对话整理)
状态	定稿方向; 企业关键输入已定 (3B 模型 / 10 部门各一套 / 图像+水声 / 保密分区强制), 见 §2.2 / §4 / §7 分区; 模块内存与烧录实测待验证, 成本估算待询价

修订记录:


- **v1.0:** 将「专用模型训练调优区 + 数据与知识底座」建设增量, 与「训练后模型部署于国产嵌入式 GPU、作为机载设备电子模块」的场景论证, 整理为研究报告; 确立**部署目标反推 → 单套训练环境定义 → 10 套形态测算**主线; 外部口径与 01 报告 v2.2 同一纪律。
- **v1.1 (2026-09-08) :** 企业四项关键输入落地——① 目标模型定为 **3B 级小语言模型** (可融合图像/水声编码); ② **10 个部门各一套**训练环境 (形态 A 定为默认); ③ 任务数据以**图像为主、可能含水声信号**; ④ **保密分区强制**, 新增 §7「涉密分区与安全架构方案」; 同步修订 §2.2/§4/§6/§8/§9 (原 §7/§8 顺延), 成本仍为估算待询价。
- **v1.2 (本版, 2026-09-08) :** 新增 **§10 指标收口默认值** (与 11 号稿 v1.4 P49 对齐)——机载任务正确率双基线三判据、时延任务分级、平台级 3B 装入、采购放行门与保密三证据; 默认值为【建议, 待业务/保密办书面校准】, 不写成定稿事实; 同步附录速查加行。

一行结论: 企业自训 **3B 级小语言模型 (可融合图像/水声信号编码)**, 经 QAT 量化后烧进机载设备的**昇腾 Atlas 200I A2 端侧模块**; 据此需要 **10 个部门各一套独立训练环境 (形态 A 定案)**——因**保密分区强制**, 各环境物理隔离、数据模型只进不出。每套 = 小型"训—量(QAT)—转—烧—验"闭环: 训练用昇腾 910B 系 (与 200I A2 同 CANN 生态), 配套数据/转换/烧录验证台。**单套估算 ¥150250 万 (标准档) / ¥60120 万 (轻量档)**, $\times 10 \approx \text{¥600} \sim \text{2500 万量级 (待询价)}$, 另加分区机房、独立配电与三员运维。

一、缘起与定位：从"在线推理"到"训—埋—机载"

01 号报告与 11 号方案解决的是"企业内网跑模型"（96 卡在线推理双池）；本文解决的是它的另一半——"企业自训专用模型，并把它部署进自有产品的机载电子设备"：

- 11 号方案中，这部分对应 P15「产品智能化转型：要造/调专用模型」，当时只做到"识别需求 + 预留架构（P29）"，**规模刻意未测算**；
- 本次讨论把部署形态**锚定**下来：训练产物 = 可烧录进**国产嵌入式 GPU（作为机载设备电子模块）**的量化模型。此锚定改变了一切量级判断：从"数据中心里很多人并发用"变为"每个模块独立跑一份、数量 = 装机套数"。
- 红线不变且更强：机载研制多涉内网/保密要求，**训练环境须能物理隔离、断外网、介质受控**——比 01 报告"数据不出域"更硬。



二、部署目标反推：模型体量上限由机载模块决定

2.1 反推链（本报告主线）

1. **机载模块约束**：内存（几 GB~十几 GB 量级）、算力（几十 TOPS 量级 INT8）、功耗/散热、宽温抗振、确定性时序 → 共同决定可烧模型的上限；

2. **模型形态**：机载场景分两类——
- **视觉/信号/目标识别类**：中小 CNN/ViT 网络（权重量级 MB~GB），**数据重、算力轻**；
 - **小语言模型**：若模块内存实测允许（边缘模块典型 ~~816GB~~ 量级），~~可烧 1B3B 的~~ INT8/INT4 小 LLM——对已选 **Atlas 200I A2** 是否可行、能上多大，取决于其内存实测（见 §2.2 待复核项）；7B 级通常不现实。
3. **训练环境规模**：由"模型上限 + 数据集规模 + 并行项目数"三者反推，而非由"在线并发人数"决定——与 01 号报告"人头不是负载、人时才是"同构，这里是"型号数不是负载、同时训的作业才是"。

2.2 部署芯片已选定：昇腾 Atlas 200I A2（企业 2026-09-08 输入）

- **形态**：昇腾**端侧 AI 加速模块**（边缘 NPU，昇腾 310 系；工程形态可作机载设备电子模块评估；有 Ind「高可靠/工业级」产品线，是否选用待定）；
- **生态优势（关键）**：与训练侧昇腾 **910B/CANN 同源**——训练用 MindSpeed/ModelLink，部署侧走 CANN 端侧 runtime + MindIE 量化导出链，"训→量(QAT)→转→烧"整条软件链同一套工具生态，跨厂商时"训一套、转一套"的适配摩擦在这里最小；
- **规格待复核**：算力/内存/功耗以华为官方 HiAscend 产品规格页为准——本报告**不臆造精确值**；公开渠道口径为"端侧 TOPS 级加速模块"（约几十 TOPS 以内、内存典型边缘模块 8~16GB 量级，仅作量级参考）；
- **企业已定目标（2026-09-08）**：模块上跑 **3B 级小语言模型**（可融合图像/水声编码）；任务数据以**图像为主、可能含水声信号**。仍待 datasheet/实测确认一项：选 **A2 基础版还是 Ind 高可靠版**、**模块内存容量**——决定"3B INT4/INT8 权重 + 编码器 + 运行缓冲"能否装入。

注：模块内存实测前，模型体量数字都是假设。本报告的方法是"定模块→实测约束→反推模型→定训练环境"。已选 Atlas 200I A2 意味着：模型大概率是**视觉/信号识别类中小网络**，或（若内存允许）≤3B 级 INT4/INT8 小语言模型；7B 级通常不现实。


三、单套"训练环境"的定义（六个组成部分的闭环）

机载专用模型的训练环境，不是"几台训练机"，而是把**从数据到上机跑通**的最小研制单元：

#	组成	内容	要点
1	训练算力	昇腾训练整机（如 Atlas 800T A2, 8×910B 64GB）×1 台	7B 级全参 SFT/LoRA 单机可覆盖，≤3B 更富余； 推理卡（300I A2 等 PCIe 卡）不能承担训练 ，须训练卡体系（HCCS + CANN 训练栈）
2	训练软件栈	CANN + torch_npu + MindSpeed / ModelLink（DP/TP/序列并行、	与在线推理栈不同，属训练栈能力

#	组成	内容	要点
		ZeRO) + 实验留痕	
3	数据环境	领域数据（图像/信号/任务样本/少量语料）采集—清洗—标注—增强—密级管理	机载专用模型的第一稀缺资源是任务数据，不是算力
4	QAT 与量化转换链	量化感知训练(QAT)、蒸馏；训完 W8A8/INT8/INT4 导出模块 runtime 格式	没有这条链，训出的模型上不了机——机载模块多为 INT8/INT4 定点运行
5	烧录与真机验证台	接目标模块的调试板/工装：精度对照、确定性、时序、功耗、温箱抽查	机载/军品对"回归可复现"要求高于数据中心
6	版本与配置管理	数据集版本/模型版本/量化配置/烧录批次留痕	支撑型号研制与追溯

（涉密研制场景整套装于隔离内网：断外网、软件与模型白名单介质导入——同数据不出域红线。）



Syntax error in text
mermaid version 11.17.2

四、10 个部门各一套：形态与单套规模测算（v1.1 定案：形态 A）

4.1 定案：形态 A • 10 套独立环境（企业 2026-09-08 决定）

- **企业口径：**"10 个部门各一套"；且**保密分区强制** → 每套为物理隔离的独立环境，数据/模型只进不出；
- **形态 B（集中算力池共享）** 仅作备选，只适用于保密办确认"允许共享/非密"的部门（多数部门同密级且无网级隔离要求时，可退化为"分域分区 + 设备独立、非网级隔离"——布点与成本可下调，列入 §8 待保密办确认项）。

4.2 单套配置两档（适配 3B 目标）

档位	单套组成 (3B 微调/蒸馏规模)	一次性规模 (估)	×10
标准档 (部门多人/数据量大)	训练整机 8×910B (64GB) ×1 + 数据/转换/烧录验证台 + 独立柜与配电	¥150250 万/套	¥15002500 万
轻量档 (部门 1~3 人/数据量小)	2~4 卡训练小机 + 数据/转换/烧录验证台	¥60120 万/套	¥6001200 万

(均含软硬件栈与密管基础；单价**估算待询价**。另加：分区机房、独立 UPS、三员运维——见 §7。)

4.3 说明

- 训练区为**独立于 96 卡在线推理的另一类采购**（训练卡体系），电力/柜位在建设方案中与在线推理**错峰复用或单独扩容**，避免双峰值叠加；
- 3B 级训练属中小规模：单卡即可跑 LoRA/SFT，8 卡机是给部门内多人排队与后续更大模型留的余量——先按部门实际人数定档，不必全部顶格标准档。

五、支撑建设内容（若并入 11 号建设方案需增加的部分）

1. **部署目标约束页**：机载模块型号/内存/算力/功耗 → 专用模型体量上限与形态（补足 11 P15"产品智能化"的空泛）；
2. **训—转—烧链路工程页**：QAT/量化/转换/真机回归，替代"能训能调"的笼统表述；
3. **训练区硬件新类**：训练整机（910B 系）与电力/机房扩容，**独立于在线推理 96 卡采购清单**；
4. **数据与知识底座（C 区）优先级**：领域任务数据的**采集标注管线**优先于通用语料治理——机载模型的瓶颈是任务数据，C 区是训练区的"原料厂"；本次任务**图像为主、可能含水声信号**，应分别建立图像/视频标注管线与水声（→时频图）处理管线；
5. **MLOps/模型治理**：实验、数据集、模型、评测、烧录批次五件套留痕；与 AI 网关、在线池的关系（专用模型是否同时进在线池另议）；
6. **组织与预算**：训练算法/数据/验证人力从"预留"转为分档测算（按 10 部门各一套的运维口径，含保密三员）；保密办前置参与 §7 分区方案的细化。

六、成本总览与分期建议（估算，待询价）

阶段	内容	一次性规模 (估)	说明
前期 POC	1 个型号先跑通"训—量—转—烧—验"闭环	单套训练整机 + 数据台： ¥150250 万	先验证数据可得性、3B 装入模块实测与真机达标率，再铺 10

阶段	内容	一次性规模 (估)	说明
			套
形态 B (备选)	集中 2~3 台训练机 + 工位 (仅非密/允许共享部门)	¥500900 万	若保密办确认部分部门可共享时采用
形态 A (定案默认)	10 部门各一套独立环境 (保密分区强制, 见 §7)	¥6002500 万 (按标准/轻量档)	POC 达标后分批铺
二期扩容	按型号需求 + 数据量实测	专项测算	与在线推理配电错峰复用


七、涉密分区与安全架构方案 (10 部门各一套 · 保密分区强制)

定位：本节为**架构级分区方案** (v1.1 新增, 回应企业"保密分区强制"输入), 供立项与建设讨论; 涉密合规细节 (密级界定、适用条款、三员岗位设置等) 须由保密办与主管部门按企业保密资格审定, 本节不作合规结论。

7.1 分区目标与原则

- 10 部门各一套训练环境, 机载型号多涉密 → 采用"**一密一网、按套隔离**": 每套环境是独立的**最小封闭域**, 彼此及与外部均无网络连接;
- 数据/模型只沿**受控单向链路 (摆渡) **进出, 杜绝越权流动; 全程可审计;
- **三分离并治**: 网络隔离、介质管控、人员权限 (三员分立) 。

7.2 分区拓扑 (建议)



7.3 关键控制项

控制	措施
网络	涉密训练域断外网、无无线; 与办公网 / 在线推理区物理隔离; 域间不设网联
摆渡	集中 1~2 处受控摆渡站: 白名单、杀毒、哈希、来源与密级登记; 专盘专用、加密、进出双向登记
介质与外设	USB / 光驱禁用或管控; 打印审批; 禁私带介质出区
人员	三员分立 (系统 / 安全保密 / 审计); 最小授权 + 关键操作双人复核
日志审计	训练作业、数据访问、模型出区全程留痕, 只读镜像汇聚监管区
分区布点	每部门 1 机柜单元 (训练机 + 数据 + 转换 + 烧录验证台 + 独立 UPS / 配电), 物理分柜分区; 同密级可相邻共管、异密级隔开
供应链	框架 / 权重 / 驱动经摆渡站导入并校验、来源登记, 杜绝供应链污染

7.4 与形态 A 的对应与提示

- **10 套环境 = Z3 内 10 个密闭域**：硬件一次建、密管一次审，建议 POC 先建 1 个域验证，再复制；
- **提示**：单部门是否真需"网级隔离"取决于保密办对**部门密级是否一致**的界定——若多数部门同密级且属同一涉密网络，可退化为"**分域分区、设备独立、非网级隔离**"，布点与配电成本相应下调（列入 §8 待确认项）；
- 此分区方案只覆盖训练域（Z2/Z3/Z4）；在线推理 96 卡（01 报告）与训练域之间的关系（是否跨网、是否需单独评估）另由信息/保密体系整体论证。

八、风险与待确认输入（数字纪律：假设不写成事实）

8.1 关键待确认 / 待实测（企业 4 项输入已定，余项如下）

#	待确认项	影响
1	模块/型号 → 已定 ：昇腾 Atlas 200I A2；仍待：A2 基础版 vs Ind 高可靠版 、 模块内存容量 （官方 datasheet 复核）	决定 3B + 编码器能否装入 (§2)
2	3B 装入模块实测门禁 ：INT4/INT8 权重大小、推理速度、时序/功耗（模块样机先导试验）	方案成立性 (§2/§7)
3	10 个环境含义 → 已定 ： 10 部门各一套（形态 A） ；形态 B 仅备选 (§4)	—（已消解）
4	任务类型 → 已定 ： 3B 小语言 + 图像为主/可能水声	影响数据管线 (§5-4)
5	保密分区 → 已定 ： 强制 ；仍待保密办对部门密级界定（可否同密级共享、降为分域分区）	网级隔离强度与布点成本 (§7.4)
6	训练整机/小机与配套单价（询价）	全篇成本由估算转实测 (§4/§6)
7	可授权训练的数据规模（图像/水声标注量）	数据投入的主导变量

8.2 主要风险

风险/假设	影响	缓解
低估任务数据成本（图像/水声采集标注）	训练区真实瓶颈在数据而非算力	POC 先在 1 个部门建数据集验证可得性，再铺 10 套
3B + 编码器超出模块内存/算力	方案不成立	模块样机先导试验压测（显存/速度/时序）；必要时降编码器/INT4/蒸馏 (§8.1-2)

风险/假设	影响	缓解
保密合规细化（三员/摆渡/介质/密级界定）落地慢	立项与建设节奏	保密办前置参与 §7 方案细化并先行审定
训练栈与在线栈生态差异（MindSpeed 训练 vs MindIE 推理）	需要两套软件能力	人力与厂商支持按两线编制
量化后真机精度/确定性不达标	上不了机	QAT 前置 + 真机回归台 (§3 组件 4/5)

九、方法论沉淀

- 部署目标反推**：先定"模型装进什么"，再反推模型上限与训练环境——任何"专用模型"需求先过这一问；
- 训—量—转—烧闭环**：机载/嵌入式 AI 的交付单元不是"模型权重"而是"可烧录、可回归的量化制品"；
- 型号数≠负载**：与"人头≠负载"同构——项目制训练按"同时训的作业"买算力，不为闲置买单；
- 数据先于算力**：专用模型的稀缺资源是任务数据，训练环境的预算重心应偏数据与验证；
- 分区即形态、合规前置**：保密分区一旦强制，形态与预算即被锁定 (§4/§7) ——立项前先与保密办对齐"密级界定 / 三员 / 摆渡 / 介质"，避免按错误拓扑买设备。

十、指标收口默认值（与 11 号稿 v1.4 P49 对齐）

为让 02 与 11 号稿验收口径一致，机载专用模型（引擎 B）的验收指标按下表收口；A·在线的收口（warm/cold 首包、解码 P95 等）见 11-P49 / 01 号报告。**以下默认值均为【建议，待业务与保密办书面校准】**，不写成定稿事实。

收口规则：每个指标带 **5 属性**——**目标 / 统计口径 / 测试条件 / 证据 / 不达标回退**；A·在线按 **P95** 收口，B·机载按"平台级 + 任务级、额定工况最坏值"收口。

层	指标（B·机载）	默认值【建议，待校准】	口径/条件	证据	不达标回退
业务·任务级	任务正确率	≥ 现状基线 ，且 ≥ 参考上界 90% （分类/识别类；生成/问答类 ≥ 85%）； INT4 相对 BF16 退化 ≤2pp （分类类）	固定回放集（企业真实数据，双人标注真值，版本冻结）	任务级验收	增数据 / 蒸馏 / 换档

层	指标 (B·机载)	默认值【建议, 待校准】	口径/条件	证据	不达标回退
业务·任务级	端到端时延	S1 短任务 ≤200ms(P95)/≤500ms(最坏); S2 LLM 单轮 ≤128 token 整轮 ≤5s (上限 15s)、首 token<1s; S3 后台分钟级	额定工况最坏值 + 典型工况	模块样机实测	降量化 / 蒸馏 / 调整任务分配
平台级	3B 量化后装得进	INT4 体积 + 编码器 + 缓冲 ≤ 模块可用内存; 推理速度/时序/功耗达标	模块样机先导	官方 datasheet + 实测	降编码器 / INT4 / 蒸馏
采购放行	POC 门	"装得进 + 跑得动 + 精度达标" 且 保密预检三证据通过	POC 验收门	样机 + 保密办	缩小试点 / 等栈成熟 / 重审方案

保密分区收口 (三件会签证据, 见 §7) : ① 《密级界定与分域方案》保密办会签 (按型号/项目密级切域, 同密级共域、设备独立); ② 三员任命到位 + 权限矩阵最小化; ③ 现场检查通过 (摆渡/介质/网隔/双人复核) + 试运行 1 个月无违规 → 出具《预检通过报告》, 作为采购放行前置。

放行逻辑: POC 达标 → 提交正式采购 (按"基准档 + 最大需求上界"两版, 见 11-P50); 部分达标 → 只扩试点或走上表"回退"列; 主门禁 (采购放行行) 不达标 → 不采购、回方案层重审。

附录：关键参数速查

参数	值	状态
单套训练算力	训练整机 (8×910B 64GB) ×1 (标准) / 2~4 卡小机 (轻量)	假设, 型号待询价
单套环境规模	¥150250 万 (标准) / ¥60120 万 (轻量)	估算, 待询价
形态 A (定案: 10 部门各一套)	¥6002500 万 (按档); IT 6080kW	已定 (2026-09-08); 成本估算待询价
形态 B (备选: 集中 + 工位)	¥500~900 万	仅非密/允许共享部门
目标模型	3B 级小语言模型 (可融合图像/水声编码)	企业已定 (2026-09-08); 装入 200I A2 可行性待模块实测

参数	值	状态
部署芯片	昇腾 Atlas 200I A2 (端侧 NPU 模块)	企业选定 (2026-09-08) ; 子型号/内存以官方 datasheet 复核
训练芯片	昇腾 910B 系训练整机 (如 Atlas 800T A2, 8 卡)	假设, 型号待询价
训练/在线关系	训练区独立采购 (训练卡体系), 与在线 96 卡不同类	定稿 (方法层)
指标收口 (B · 机载)	正确率双基线三判据 / 时延任务分级 S1~S3 / 保密三证据	【建议默认, 待业务/保密办校准】 (见 §10)