

11 · 企业 AI 基础设施建设方案建议（高层汇报稿）

文档信息	
编号	11
版本	v1.5（汇报故事板 · 56 页 · 含指标认知层，2026-09-08）
日期	2026-09-08
受众	企业高层（汇报，非决议）
来源	01 号研究报告（在线推理 v2.2）+ 02 号研究报告（训练与机载部署 v1.2）
篇幅	56 页 / 约 30 分钟（P01–P13 目标与验收标尺 → P14–P19 指标认知 → P20 起两引擎推导与构成 → P54–P56 统一推进/指标收口/汇报收口）

体例说明：本文是 **PPT 故事板**，每页 = 大标题 + 上屏要点 + 图/表 + 「备注」（讲者话术与出处，上屏时剔除）。方括号〔Qn〕/〔§〕指向 01 号报告问答与章节，供核对。正文所有金额为**估算、待询价**，卡数为**测算、待 POC 校准**——口径统一在本稿 P03，正文不逐页重复。

修订记录：v1.0（2026-09-07）初稿。v1.1（2026-09-08）随 01 号报告 v2.2 外部事实核校修订——① 模型上下文口径按官方公开资料更新（P08）；② 27B 不再表述为「1M 能力」，改「原生 262K、官方支持外推至 1M」；③ Flash-Next 昇腾软件栈成熟度由「就绪」降为「待 POC 验证」，并在 P30/P45 显式化；④ P33 单位勘误（10 **实例** × TP8）。**v1.2（2026-09-08）基于 01-v2.2 + 02-v1.1 修订——⑤ 产品智能化锚定机载专用模型**（P21：3B 小语言 + 昇腾 Atlas 200I A2 模块部署）；⑥ 训练调优区由「预留」升为「已出专项 02 号」（P11/P28/P35：10 部门各一套 · 保密分区）；⑦ P44 明确训练/数据区为**独立专项、不计入本期账**；⑧ P45/P46 增加训练区「3B 装入模块实测 + 保密分区」两道门禁。**v1.3（本版，2026-09-08）结构与叙事重构——B 区（机载专用模型训练）并入主体、立为引擎 B**，与引擎 A（在线推理）及数据底座 C 构成**一份整体方案**；统一推进节奏（P54）与统一收口（P56）置末，删除「主故事 + 专项备份」式分段；页码按新顺序全篇重排并自动重映射引用；每页指标均补「原理 / 为什么能满足」行。****v1.4（本版，2026-09-08）**收口定稿——P55 扩为「指标收口」（A/B 三层验收总表 + 放行矩阵；默认值【建议，待业务/保密办校准】）；P56 明确「本次请批三项论证（两个 POC + 数据盘点/保密细化）、非采购」，并新增正式采购「最大需求上界」参考（A+B ≈¥3000~4400 万量级，估算待询价）。**v1.5（本版，2026-09-08）**按需扩页至 56：P13（SLA）后新增 **P14–P19 指标认知层**——输出速率、并发数、上下文长度、首 token/首包延迟各由什么物理因素决定 + 人的正常期望，及「训练 vs 推理为何是两类卡」，其后页码整体 +6 重排并重映射引用；本行 v1.1–v1.4 所述页码为该版历史页序。口径承诺见 P03。**

P01 • 封面

企业 AI 基础设施建设方案建议

- 副题：一个底座，支撑四类企业 AI 需求——产品智能化、产品数据开发、AI 技术研究、AI 办公
- 一句话结论：企业 AI 基础设施 = **引擎 A•在线推理** (96 卡) + **引擎 B•机载专用模型训练** (3B → Atlas 200I A2, 10 部门各一套) + **数据底座 C**——一份整体方案，B/C 独立立项、全口径见 P56
- **投资口径 (估算•待询价)**：引擎 A 正式采购 ~~CapEx ¥8501100 万 / 年运营 ¥110160 万~~；引擎 B POC ~~¥150250 万 → 10 部门两档 ¥6001200 / ¥15002500 万~~；**A+B 整体预算边界 ~~≈¥30004400 万**~~ (C 与人力另计，仅锁预算上界，见 P56) ——**本次请批的是论证 (两个 POC + 数据盘点/保密细化)，非采购**
- 汇报人 / 2026-09-09 / 编号 11

备注 (约 20 秒)：今天约二十五分钟，汇报**一份完整方案**——引擎 A 在线推理 + 引擎 B 机载专用模型训练 + 数据底座 C。**请各位批准的不是采购，而是三项论证启动**：引擎 A、B 两个小 POC (各约 ¥150~250 万级) + 数据盘点与保密细化；POC 验收达标后再提正式采购 (届时按"基准档 + 最大需求上界"两版，全口径见 P56)。所有数字可追溯到编号 01/02 报告。

P02 • 汇报主线

1. **为什么建** —— 企业 AI 需要从"零散试点"升级为"基础设施"
2. **建成后验收什么** —— 三层能力 + 可验收的 SLA
3. **企业要用 AI 干什么 (四类需求)** —— 需求 → 基础设施诉求
4. **基础设施建什么** —— 在线推理 + 训练调优研究区 + 数据底座
5. **每一组成部分为什么是这个量** —— 从需求推导 (本次汇报的重点)
6. **节奏与风险** —— 分期、POC、风险预防

备注 (约 30 秒)：今天六步讲完。请各位特别留意第五步——我们会把"为什么大约一百张卡、为什么这套软件、为什么这个电力和机房"逐一从需求推出来，让预算的每一项都有出处。**这是一份整体方案：引擎 A (在线推理) + 引擎 B (机载专用模型训练) + 数据底座 C，共享公共设施、同一张口径——不分主备，先讲整体再讲各自构成的量。**

P03 • 一句话方案 + 全稿口径

一句话方案：建设企业 AI 基础设施——引擎 A · **在线推理**（双池 96 卡，约 100 张）为一期落地主体；引擎 B · **机载专用模型训练**（3B 小语言 → 昇腾 Atlas 200I A2 机载模块，10 部门各一套）与**数据与知识底座 C** 为同一方案的组成部分——B 本期不采购、POC 达标后独立立项；三部分共享公共设施、同一张口径表。

口径承诺（全稿有效，正文不重复）：

数据类别	口径	状态
金额（CapEx/OpEx）	引擎 A 按 01 报告口径；引擎 B 按 02 号档位	估算，待询价
卡数（16+80=96）	由需求口径测算	测算，待 POC 校准（±20%）
KV/带宽等物理参数	官方 + 假设	假设项待实测
引擎 B（训练）与 C（数据底座）规模	B：02 号已测算档位（P45–P53）；C：随盘点	估算待询价、POC 先行；本期不并表，全口径见 P56
报告状态	定稿	POC 待验证

备注（约 30 秒）：请允许我先立一个规矩——本稿**每个数字都能追到出处**（编号 01 报告的问答实录）；带"估算/测算"的，落地前都要经过询价或一期 POC 验证。哪些是已算清楚的、哪些是需要下一步专门测的，P03 这张表会一路标到底。

P04 • 现状与痛点：今天为什么必须动

- **研发侧：**编码/调试/设计文档的 AI 用量在涨，但受制于公网不稳、速率不确定——真正敢把"整仓代码 + 设计文档"交给 AI 的很少
- **办公与管理侧：**问答、管理类报告主要靠人——业务数据散、整理靠手工，AI 帮助有限、质量不可控
- **共同问题：**数据出境（代码、业务数据在公网服务上）、额度墙（用量一高就受限）、能力无法积累（提示词/知识/模型 Know-how 都留在外部）

备注（约 40 秒）：这是今天要解决的问题。各位可以回想：我们这些年用 AI 是"借别人的工具"，能力强弱、稳不稳定、数据去哪，都不由我们控制。基础设施建议，本质是把"借工具"变成"建自己的能力"——让能力、数据、模型都沉淀在自己企业里。这些痛点在 01 报告背景部分有详细展开〔01-§1〕。

P05 • 目的总述：从"零散试点"到"基础设施"

把企业 AI 从**单个试用**升级为**一项基础设施**，三层含义：

1. **算力资产**：一次规划、随业务增长平滑扩容，不再每次单点采购
2. **数据资产**：业务数据有序接入、分级、沉淀，成为企业可复用的原料
3. **模型与 Know-how 资产**：专用模型的训练/调优经验、评测、运维方法都留在企业内

备注（约 30 秒）："基础设施"是关键词。就像建了电力和网络，任何新应用都能用；AI 基础设施一旦建成，四类需求（后面会讲）都在这张底座上生长，而不是各买各的、各建各的。

P06 • 目的之支撑：四类企业需求共用一张底座

未来企业 AI 的四大用场，都在这张底座上跑：

#	需求	一句话
①	产品智能化转型	企业产品要"带 AI"，需要专用模型，能训能调
②	基于 AI 的产品各数据开发	用 AI 批量开发/加工产品侧数据与语料
③	AI 技术研究	跟踪、试验、评测新模型与新技术
④	AI 办公	业务数据分析与整理、管理类报告编制、问答等

备注（约 30 秒）：这四类不是并列的小工具，而是未来企业运营里会同时出现的四类刚需。它们对基础设施的诉求不同——有的要"在线推理"、有的要"训练调优"、有的要"数据底座"。P06 先立这个全景，第三部分逐类展开。

P07 • 目的之红线：数据不出域、合规与权属

- **数据不出域**：研发代码、业务数据、管理材料，全部在企业内网闭环处理（这是私有化建设的首要红线）
- **权属归企业**：基于开源基座训练的领域专用模型，权属、部署、演进完全自主
- **可审计**：AI 网关对"谁在什么时间调用了什么、数据流向哪"全程留痕——既是内控，也是合规抓手

备注（约 30 秒）：为什么选自建而不是继续租公网？很多理由在后面，但**最硬的一条是红线**：当我们认真要把 AI 用到产品、用到研发代码、用到业务数据上时，"数据不出域"就不是可

选配置，而是前提。01 报告里有句结论：出域红线存在时，私有化没有对手〔01-§6.1〕。

P08 • 目的之时点：为什么是现在

- **模型就绪**：千问 3.8 (2026-08) ——27B 稠密 (Apache 2.0 可商用；原生 262K 上下文，官方支持外推至 1M) + Flash-Next MoE (官方宣传支持 1M 上下文、低成本)，首次在可接受成本内覆盖"长上下文研发 + 全员问答/报告"
- **国产卡就绪**：昇腾 Atlas 300I A2 (64GB, 1.6TB/s) 已到推理主力代际；软件栈成熟度**分层**——27B 已获昇腾 Day0 适配，Flash-Next (Qwen4 预览架构，2026-08 下旬开源) 昇腾侧算子/KV 量化/1M 支持仍在演进，**须 POC 首站验证** (见 P54)
- **用量窗口**：各条线 AI 使用量正在爬坡——现在建，爬坡期的每一次使用都在给企业自己积累数据与经验；继续等，用量继续外流、成本难控

备注 (约 30 秒)：技术选型窗口是 01 报告专门核过的〔01-§2〕。简单说：今天这个时点，"能打的长上下文模型"和"够用的国产推理卡"同时到位，自建第一次在经济上成立。P08 只讲时点，为什么这套组合在第五部分展开。

P09 • 目标总览：建成后验收什么

建成后验收**三层能力 + 一套可验收的体验指标**：

能力层	内容
A · 在线推理	研发 1M 长上下文 Agent 环常态化；全员流畅级问答/报告
B · 训练调优与研究	专用模型能训能调；AI 研究有实验田
C · 数据与知识底座	业务数据接入—分析整理—分级入库，反哺问答/报告/训练
体验	一套明确 SLA (P13) ——"好不好"是可验收的句子，不是感觉

备注 (约 20 秒)：P09 是给大家一张"验收地图"。这一页之后，P10–P13 逐层讲三层能力和一套 SLA；**P14–P19 先讲清这些指标各由什么决定、人对它们的正常期望**，再进入需求与规模推导。

P10 • 目标 A • 在线推理：研发 1M Agent 环 + 全员流畅问答/报告

- **研发 (Agent 环)**：编码、调试、设计文档能放进 **1M 上下文**——整仓代码 + 设计文档一起给 AI, Agent 真正可用
- **全员 (问答/报告)**：短问答与报告生成达到“**流畅级**” (60~80 tok/s, 见 P13 标尺)
- **三类负载错峰共池**：研发白天碎片 + 报告集中段排队填谷, 互不挤死

备注 (约 30 秒)：这是把“研发 Agent 环”和“办公问答报告”说清楚的一页。1M 上下文不是炫技——研发场景的代码与设计文档天然就是长文本, 这是 01 报告反复校准过的真实口径 [01-Q23/Q24]。

P11 • 目标 B • 训练调优与研究：专用模型能训能调、研究有实验田

- **产品智能化**：企业产品要内嵌 AI, 通用基座不能直接出厂 → 基于开源基座 (千问系) 在企业内做**领域专用模型的训练与调优**
- **AI 技术研究**：试验、评测新模型/新方法需要一个**弹性实验田** (利用率天然波动, 与在线推理错峰)
- **目标表述**：不是“本期建多大训练集群”, 而是“**下一批机载专用模型能造、能调、能烧、能验**”——专项已出 (02 号: 10 部门各一套训练环境, 见 P35), **本期仅预留不采购**

备注 (约 30 秒)：01 号报告测算的是“跑模型”; 产品智能化要的是“造/调/烧模型”——是两件事, 也是企业真正的护城河。这部分已随 02 号报告出专项方向: **机载专用模型 (3B) + 10 部门各一套训练环境 + 保密分区** (P21/P35 细讲); 本期只识别预留、不采购, 避免把两块预算混在一张账里。

P12 • 目标 C • 数据与知识底座：业务数据能进、能理、能用

- **接入与分析整理**：各业务系统的数据有序接入, 做**分级、清洗、分析、整理、入库** (AI 办公场景的核心诉求之一)
- **分级授权**：不同密级的数据服务不同场景, 合规边界清晰
- **反哺闭环**：整理后的数据成为三件事的原料——问答/RAG 的知识来源、管理报告的素材、训练调优的语料

备注 (约 30 秒)：问答好不好、报告像不像样、专用模型训得专不专, 底层都取决于**数据有没有被好好整理分级**。所以方案里它是一条独立的“数据与知识底座”, 而不是一个散功能。规模与建设节奏放在 P36, 同样待专项。

P13 • 目标：一套可验收的体验标尺（SLA）

感知阶梯（流速 → 体感）：

流速	体感	判断
<20 tok/s	拖沓	不可交付
20~40	勉强	保底
40~60	及格（公有云底部区间）	验收线
60~80	流畅（超阅读极限 ~10 倍）	设计目标
>100	体感无差别	仅批处理受益

四项 SLA 验收〔01-Q25〕：

- 首包 (warm) ≤ 3s (P95) | 解码 ≥ 60 tok/s (P95) | 研发 Agent 整轮 ≤ 30s | 报告排队 ≤ 10 分钟

备注（约 30 秒）：这一页是把"体验"变成**可验收的句子**。给高层验收就一句话：达到这些数=达标，达不到=我们改进。1M 场景下首包时延比速度更敏感，所以有"首包 ≤3s"这一条〔01-§5.5〕。

P14 • 指标认知① • 输出速率由什么决定 + 人的期望

- **物理公式**：每生成 1 token 要把全部权重读一遍 → 单路速率 ≈ **带宽 ÷ 每步权重字节 × 每步产出 token**
 - 27B INT8: 1.6TB/s ÷ 28GB ≈ **57~59 上限** → 工程取 ~50〔01-Q30〕
- **四条加速路（不靠并发）**：量化 INT4（字节÷2）/ MTP 投机（×1.3~2.5）/ 2 卡 TP（每卡 ÷2）/ MoE 小激活（只读被路由专家）
- **人的期望（感知阶梯）**：<20 拖沓 | ~~20~40 勉强~~ | 40~60 及格 | ~~**60~80 流畅（阅读极限 58 的 ~10 倍）**~~ | >100 无感（仅批处理受益）
- 编码 2K patch: @50 tok/s ≈ 40s 可接受; @20 tok/s ≈ 100s 烦躁

备注（约 25 秒）：回答"为什么是 50 / 60~80，不是拍脑袋"——先由**带宽 ÷ 权重字节**定物理上限，再由**人的阅读速度**定"够用线"；两条线之间的档，就是 SLA 取值区间。

P15 • 指标认知② • 并发数怎么定 + 人的期望

- **"并发"三层语义**：会话驻留（只占显存=KV）→ 解码路数（占带宽+算力）→ 硬件 batch GEMM（每步一次）
- **真正花钱的是"解码路数" $\approx$ 会话 $\times$ 占空比**：人在读 / 等工具时模型在歇——对话占空比 1025%、Agent 3040%
- **两堵墙**：容量墙 = KV 池 $\div$ 人均占用；带宽墙 = 同时解码路数 $\times$ 每步 KV 读取
- **人头 $\neq$ 并发**：2500 研发 $\neq$ 2500 路并发（后文"人时漏斗"由此把卡数推到 96）
- **人的期望**：并发承诺的是"不排队、峰值不掉速"，不是"人头数=并发数"

备注（约 25 秒）：并发的含义落到卡上是三个数，别混。预算只该为"同时真正在生成 token 的路数"付钱——这就是后面所有卡数打折的前提。

P16 · 指标认知③ · 上下文长度怎么给 + 人的期望

- **模型能力 $\neq$ 服务配置**：262K / 1M 是"模型能力"；给多少人开、开多长是**容量账**（KV 池 $\div$ 每 token 占用）
- **对话 32K 甜蜜点**：解剖 = 系统 24K + ~~工具 12K~~ + RAG 28K + ~~历史 8K~~ $\approx$ 1220K，留 $\sim$ 50% 余量
- **1M 是"能开"不是"人人常年挂 1M"**：一条 1M 会话占的 KV，可挤走大量短会话（28GB 权重之外 1M $\approx$ 120GB）
- **人的期望**：别按模型宣称值给全员开窗——按真实流量画像裁剪上下文预算，才是产品参数

备注（约 25 秒）：上下文是"花钱买的速度/容量"。给所有人默认开满 1M，等于把容量账做爆；32K 覆盖 95% 对话、1M 只给确需长上下文的场景（后文 1M 三档）。

P17 · 指标认知④ · 首 token / 首包延迟由什么决定 + 人的期望

- **首 token 时延 (TTFT) $\approx$ prefill 计算 + 排队**：长输入里 prefill 是大头（1M prefill 秒 $\sim$ 十几秒级）
- **冷/热分账**：冷载（无缓存）1M $\approx$ 11s/实例（物理）；warm 增量（前缀命中） $< 1s$ [01-Q25]
- **首包 = 流式第一批到屏 = TTFT + 网络/渲染**：与 TTFT 一并看，别只看其一
- **SLA**：warm $\leq 3s$ (P95)；cold $\leq 20s$ (P95 上限，常态经预热回 $< 3s$)
- **人的期望**：warm 3s 内"没感觉在等"；超 $\sim 10s$ 用户认为卡死——故 1M 场景 TTFT 比流速更敏感

备注（约 25 秒）：速度只是"多快出字"，等待是"多久见第一个字"——1M 场景用户骂的不是慢，是等。所以冷加载靠预热与错峰管理，别指望速度救 TTFT。

P18 • 指标认知⑤ • 训练与推理：为什么是两类卡

- **推理 = 前向，瓶颈"带宽"**：每 token 只把权重读一遍，算力几乎闲置 → 推理卡看**带宽 × 容量 × 功耗**（昇腾 300I A2，PCIe 即可）
- **训练 = 反向，瓶颈"算力 + 互联"**：要存激活/梯度、每步全卡同步参数（AllReduce）→ 训练卡看**算力密度 × HCCS 高速互联 × 大显存**（昇腾 910B 系）
- **同品牌 ≠ 同卡型**：昇腾三型各司其职——300I A2（推理）/ 910B（训练）/ 200I A2（端侧推理模块，不可训练）
- **为什么不能拿 96 张推理卡训练**：互联弱、算力密度低、无 scale-up——**训练不是"多买推理卡"，是另一类硬件**（引擎 B 必须另购 910B 的根因）

备注（约 25 秒）：一句话回答"为什么引擎 B 不蹭 A 的 96 张卡"：推理卡为"前向搬权重"优化，训练要为"反向同步"买单——两类卡的瓶颈完全不同。

P19 • 指标认知⑥ • 一张总表：数字 → 由什么决定 → 人感 → 卡

指标	由什么决定	人的正常期望	对应卡
输出速率	带宽 ÷ 权重字节 × 每步产出	60~80 = 流畅线	推理卡（带宽）
并发数	占空比 + KV/带宽两墙	不排队、峰值不掉速	推理卡 + 容量
上下文长度	KV 容量账（服务配置）	32K 对话、1M 是能力	推理卡显存
首 token/首包	prefill + 排队 + 冷热	warm≤3s / cold≤20s	prefill 算力
训练节拍	算力 + 互联 + HBM	部门"训得动、不排队等"	训练卡（910B）

备注（约 20 秒）：这页是可抄走的一张底图——每个数都回答"由什么定、人觉得够不够、靠哪类卡"。后面所有推导都回指这张表。

P20 • 主要需求全景：企业用 AI 干什么（四类）

#	需求	落到基础设施
① 产品智能化转型	专用模型训练/调优（离线·项目制）+ 产品内推理（在线）	B 造调区 + A 推理
② 基于 AI 的产品各数据开发	批量/吞吐型数据处理（可排队）+ 数据管线	A 推理（吞吐）+ C 底座
③ AI 技术研究	弹性训练/评测实验田（利用率波动）	B 造调区
④ AI 办公（业务数据分析与整理、管理类报告编制、问答等）	数据分析整理（底座）+ 管理报告（吞吐）+ 问答（在线/RAG）	A 推理 + C 底座

备注（约 40 秒）：这是今天需求章的地图。后面 P21-P24 一页一类，P25 给"需求 → 三层基础设施"的映射总图。请各位留意：**四类需求都跑在线推理与数据底座上，其中产品智能化和技术研究额外要"造调模型"的能力。**

P21 · 需求① · 产品智能化转型：造/调"装进机载设备的专用模型"

- **要什么**：企业产品（机载设备）内嵌 AI——部署形态已锚定 = **国产嵌入式 GPU 模块（昇腾 Atlas 200I A2）**，目标 **3B 级小语言模型**、任务以**图像为主 / 可含水声信号**〔02-§2〕
- **训练形态**：不是数据中心"服务模型"，而是"**训—量(QAT)—转—烧—验**"闭环——训完量化烧进模块；训练区与在线推理**分域**（涉密隔离）〔02-§3/§7〕
- **规模口径**：专项已出（02 号）——**10 部门各一套**训练环境（形态 A·保密分区强制）；单套 ~~¥150250 万（标准）/¥60120 万（轻量）~~ **估算待询价、独立于本期 96 卡采购**〔02-§4〕
- **本期定位**：训练区**本期不采购**；先由 1 个部门 POC 验证"3B 装入 Atlas 200I A2 + 保密分区落地"，达标后分批铺〔02-§6〕

备注（约 30 秒）：产品智能化含金量最高，也最容易算错——它要的不是"更大的在线池"，而是"造/调模型并烧进机载模块"的能力（02 号报告已把它算清楚：10 部门各一套、保密封闭训练域）。本期只承诺在线推理；训练区按 02 号口径单独立专项、POC 先行，不让高层误以为本期要再投一大笔。

P22 · 需求② · 基于 AI 的产品各数据开发：批量吞吐为主

- **要什么**：用 AI 批量开发/加工产品侧的数据、语料、样本（生成、整理、质检、扩量）
- **负载性质**：**批量、吞吐型、可排队**——不需要抢占式实时，适合排队论调度
- **落在哪**：并入在线推理的"吞吐队列"（与报告类同池），由数据管线承接进出

- **对质量的影响**：这类任务对精度要求分级——能用低精度档跑的就用低档，省卡

备注（约 30 秒）：需求②和需求①的区别：①是"造模型"，②是"用 AI 大规模产数据"——都是产品线在为智能化备料。这类负载**可以排队、可以打折精度**，正好填在线推理的谷（P33 的排队填谷机制服务它）。

P23 • 需求③ • AI 技术研究：要一个"实验田"

- **要什么**：跟踪开源模型演进、评测替代方案、验证新技术（如投机解码、新量化位宽、国产软件栈）
- **负载性质**：**弹性、探索性、利用率波动大**——高峰期有、空闲期闲置
- **落在哪**：研究/评测多属非涉密 → 依托 02 号训练区预留的弹性算力与在线池低谷错峰；涉密实验进密闭训练域（02-§7）
- **成本策略**：研究负载允许低优先级、可抢占；不为一时的实验去买常年闲置的算力


备注（约 30 秒）：技术研究最大的特点是"不确定"——今天不知道下季度要跑什么实验。所以它不能按确定性负载去采购，而是放进预留区、按需弹性调度。这也是为什么训练调优与研究区在 P36 一起规划。

P24 • 需求④ • AI 办公：数据分析整理 + 管理报告 + 问答

- **要什么（三层）**：
 1. **业务数据分析与整理**——把散在各业务系统的数据分级、清洗、分析、结构化入库（数据底座）
 2. **管理类报告编制**——吞吐型：给素材出报告、给口径出汇总，可排队
 3. **问答**——短问答、快问快答、RAG 式基于企业知识的回答（在线）
- **使用者**：管理/职能/办公人群，是"在线推理"里交互问答 + 吞吐报告的主要来源
- **成功标志**：管理者的"要个数据/要份材料"从"找人数天"变成"AI 数十分钟、人审校定稿"

备注（约 40 秒）：需求④覆盖人数最广，也最能被高层体感。请注意它的第一层是"业务数据分析与整理"——这决定了问答和报告的质量，所以方案把它作为独立数据底座来建，而不是塞进某个功能。这一人群的用量即 01 报告里非研发侧的问答/报告口径〔01-§5.1〕。

P25 • 需求 → 基础设施诉求映射（总图）



备注（约 40 秒）：把四类需求落到三层诉求就一句话——**人人都要"在线推理"，产品智能化和研究要"造调能力"，办公和产品数据离不开"数据底座"，三者共用一套机房电力网络运维。**接下来两页，把"在线推理到底要多少卡"这一步推出来（约 100 张卡的来源），训练调优与数据底座的规模则明确定性为待专项。


P26 • 在线推理量化锚①：人头不是负载，人时才是

- 4000 人 = 研发 2500 + 办公/管理 ~1500
- 关键：2500 研发 ≠ 2500 路并发。决定硬件的不是"多少人"，而是"同时真正在生成 token 的路数"
- 研发工时构成〔01-§5.2〕：设计+编码 ~30-35%、调试 ~25-30%、讨论评审 ~15-20%、试验 ~10-15%、事务 ~10% → **AI 活跃占比综合 ~55%**
- 占空比谱系〔01-§3〕：交互问答 1025% (人在读) | 研发 Agent 环 3040% (等工具返回) | 批量吞吐 ~100% 但间歇

备注（约 40 秒）：这一页是"卡数推导"的第一块基石——**人头不是负载，人时才是**。2500 个研发不等于同时要 2500 条通道，因为有工作间隙、有占空比。把这块想清楚，才不会把预算买在"高峰同时 2500 人都在打字"这种永远不会发生的最坏值上。

P27 • 在线推理量化锚②：卡数怎么推出来（约 100 张卡）

四层漏斗〔01-§5.2〕：



口径五轮修正，收敛到 96 卡 [01-§5.1]：

轮	口径修正	卡数
v1	1000 Agent + 3000 对话	86
v2	对话拆"交互/吞吐 (报告)"	94
v3	编码全员 1M → 三档	A'档 72 (编码池)
v4	研发核清 2500、人时漏斗	110
v5	非研发核清 ~1500	96 (终版) = 重负载 80 + 交互 16

反伪需求判据：若按"全员 1M × 500 路 × 200 tok/s"最坏值采购 → 算力只要 20 卡、带宽却要 5000 卡——**三本账失衡即伪需求** [01-§4/§8-6]。方案只按真实负载买，不为永远不发生的最坏

值买单。

备注（约 60 秒，本页是“约 100 张卡”的正面回答）：为什么约一百张卡？不是估的，是**推的**——先承认“人头不等于负载”，把人头过四层漏斗压成“峰值约 700 路解码”，再按每路带宽算卡。而且这个口径是**改了五轮**才定的：86→94→110→96，每一轮都对应一次需求核清（比如把 1000 研发核清成 2500、把非研发从 3000 核到 1500）。五轮修改本身，就是这份测算可信的证据。96 ≈ 100，就是各位在封面看到的那张卡数。

P28 • 需求小结：已测算 vs 待专项


诉求	状态	说明
A · 在线推理（问答/Agent环/吞吐）	已测算 （01 号报告）	96 卡双池，见 P30–P34
B · 训练调优与研究区（产品智能化）	已出专项（02 号）· 本期预留不采购	机载专用模型（3B）：10 部门各一套（形态 A · 保密分区），见 P21/P35
C · 数据与知识底座	识别 + 按需构建	通用语料待盘点；任务数据（图像/水声）线并入训练专项（P36）
公共设施（机房/电力/网络/运维）	按一期推理测算	训练区（独立分区/配电）与在线区关系另专项复核（02-§7）

备注（约 30 秒）：需求章收口——**在线推理这张“产线”今天能算清楚（96 卡）**；**“造调”已出 02 号专项方向（10 部门各一套、POC 先行）**；**“数据底座”随盘点构建**。本期按在线推理把公共设施建好，给训练/数据留口子，但**不并表、不在本期账里加训练区的大数**。

P29 • 总体架构：一张图 + 一个比喻


比喻：企业 AI 基础设施 = 一座 AI 工厂

- **在线推理平台 = 产线**（跑日常问答/研发环/报告，7×24）
- **训练调优与研究区 = 研发车间与实验田**（造/调专用模型、做实验，按项目开停机）
- **数据与知识底座 = 原料库与质检**（业务数据进、分级清洗、按需出料）



备注（约 40 秒）：用工厂来记：**产线（在线推理）卖力跑，研发车间（训练调优）出新品，原料库（数据底座）保质量，机房电力是厂房。**这样四类需求和三层基础设施就都能放进同一张图。接下来 P30–P37 一层层看每个车间建什么。

P30 • 内容•在线推理平台：双池 96 卡架构



- **96 卡 = 12 台 8 卡机**：交互池 16 (8×TP2) + 重负载池 80 (10×TP8)
- **前提**：重负载池以 Flash-Next 为基座——该模型 2026-08-26 才开源，昇腾侧适配 (算子 / EP-TP / KV 量化 / 1M) 成熟度须 POC 首站验证 [01-v2.2]

备注 (约 50 秒)：这是在线推理的“产线图”。两个池分工：**交互池**管短问答 (轻、省卡)，**重负载池**管研发 1M 环 + 报告/数据吞吐 (重、贵但能干重活)；中间一个 AI 网关决定请求去哪、谁优先、全程留痕。为什么 16 和 80 这两个数——P38 从需求推给你看。

P31 • 内容•AI 网关：路由、配额、审计

- **统一 API**：企业内部所有 AI 应用走一个入口，不再各接各的外部服务
- **三条路由**〔01-Q21〕：① 研发一切请求 → 重负载池；② 非研发短输入 → 交互池；③ 报告/数据批量任务 → 重负载池排队填谷（Agent 实时优先）
- **配额与优先级**：研究/批量任务低优先级可抢占，生产问答不被挤
- **全量审计**：谁、何时、调了什么、数据流向哪——合规与内控的抓手

备注（约 30 秒）：网关是"秩序层"。没有它，四类需求会互相抢资源、数据流向不可控；有了它，预算花在刀刃上，且"数据不出域、用了什么都有账"在技术上成立。P07 那条红线，落点就是这个网关。

P32 • 内容•交互池特写（16 卡）

项	配置	依据
模型	千问 3.8 27B dense (Apache 2.0)	短问答足够、成本低〔01-Q1〕
部署	8 卡 × TP2 = 16 卡	交互峰值 ~270 路解码 / ~700 会话
上下文	32K (不是 1M——对话甜蜜点)	对话解剖：系统+工具+RAG+历史 ≈12~20K〔01-Q15〕
精度	W8A8 + KV INT8	精度/容量平衡
速率	50 tok/s 档	面向问答，不上限保底

- ▶ **为什么 50 tok/s 达标（原理）**：27B INT8 单路上限 ≈ 带宽 ÷ 权重 = 1.6TB/s ÷ 28GB ≈ 5759 tok/s〔01-Q30〕；交互取 50 档留余量，峰值 ~270 路由 batch 聚合承载——**达标靠带宽账 × 占空比，不靠堆卡**

备注（约 30 秒）：交互池负责"轻活"——为什么 16 卡就够：短问答占空比低（人读的 75% 时间模型在等），峰值 ~270 路解码折算下来 16 卡富余。注意它只给 32K 上下文，不给 1M——**给所有人开 1M 是把钱花在没人用满的能力上**（P27 反伪需求）。


P33 • 内容•重负载池特写（80 卡）

项	配置	依据
模型	千问 3.8 Flash-Next MoE (125B 总参 / 6B 激活)	重活成本最优 [01-Q1/Q16]
部署	10 实例 × TP8 (每实例 8 卡) = 80 卡	Agent 环 825 + 快问 550 + 吞吐队列
上下文	1M 能力 (KV INT4)	研发整仓代码/设计文档 [01-Q23]
速率	60~80 tok/s (SLA)	流畅级设计目标 [01-Q25]
调度	排队填谷：报告/数据任务填 agent 碎片谷	负载时间互补 [01-\$5.3]

- ▶ **为什么 60~80 tok/s 达标 (原理)**：Flash 激活仅 6B → 每 token 权重读取 $\approx 27\text{B}$ 的 $1/4.5$ ($\div 4.5$)，叠加 QSA 稀疏读 $\div 8$ 与 KV INT4，单路带宽余量成倍放大 [01 \$3 三重减免] ——SLA 60~80 是聚合账下的设计目标，不是超配

备注 (约 40 秒)：重负载池是"研发环 + 重活"的家。80 卡是怎么由 700 路峰值解码折出来的、为什么用 MoE 低激活模型来省每路带宽，P38 推给你。这里先记结论：****它在 1M 下仍给到 6080 tok/s 的流畅体验****。

P34 · 内容·1M 上下文怎么给：三档选型，起步 A'



为什么 A' 起步：Agent 占空比 35% = 65% 时间会话在"睡觉"——**不为睡觉的 KV 买 HBM**。先 A' 上量，软件成熟后演进 B 档再省卡 [01-\$5.4/Q23]。

备注 (约 40 秒)：1M 是"能力"不是"默认每人都常年挂 1M"。同样给人开 1M，最贵的硬上法要 200 卡，**量化到 KV INT4 只要 96 卡**——卡数差一半，靠的就是"不为睡着的人留床位"和"把缓存压紧"。起步 A'、成熟上 B，是分期里"再省 8~20%"的来源。

P35 · 内容·训练调优与研究区（产品智能化 · 依据 02 号专项）

本期定位：专项已出（02 号 v1.1）——企业产品（机载设备）专用模型 = **3B 级小语言模型**，训后量化烧进 昇腾 Atlas 200I A2 机载模块；训练区 = **10 部门各一套**独立环境（形态 A · 保密分区）。**本期不采购**，先 POC。

- **单套构成：**"训（910B 系）—QAT/量化—转换—烧录—真机验证"闭环 + 任务数据台；标准档 8×910B 整机 ¥150250 万/套、轻量档 24 卡 ¥60~120 万/套（估算待询价）〔02-§3/§4〕
- **保密分区：**10 套为物理隔离封闭训练域，数据/模型经受控摆渡进出，系统/安全保密/审计三员管理〔02-§7〕
- **POC（建议先做）：**选 1 个部门跑通"3B 训—烧—验"，先验两件事——**3B 装入 Atlas 200I A2**（显存/速度/时序）、**保密分区与三员落地**〔02-§6/§8〕
- **与在线推理关系：**训练用昇腾训练卡（910B 系），与在线推理（300I A2）是**两类采购**；训练区独立分区/配电，与在线 96 卡不混账

备注（约 40 秒）：这是"造/烧模型"的车间。02 号报告已把"要训什么、要几套"锚定：机载专用模型 3B、10 部门各一套、保密分区强制。但**金额仍是估算、且 3B 是否装得进 Atlas 200I A2 必须先实测**——所以本期一张训练卡都不买，先花一个小 POC 验证这两点，达标再立专项、分批铺。规模待确认项（模块内存、密级界定、询价）见 02-§8。

P36 · 内容·数据与知识底座（预留 / 按需构建）

本期定位：识别需求 + 明确做法，规模随数据盘点专项。

- **接入与整理：**业务系统数据接入 → 分级、清洗、**分析与整理**、结构化入库
- **分级授权：**不同密级数据服务不同场景（如管理报告用经营数据、问答用制度与知识库），合规边界写进授权
- **反哺三件事：**问答/RAG 的知识来源、管理报告的素材、训练调优的语料
- **依托公共设施：**主要吃存储 + 吞吐推理 + 治理流程，**不是又一座大规模算力池**

备注（约 40 秒）：数据底座是需求④（办公）和质量的地基——**问答答得准、报告像样、专用模型训得专，都取决于数据有没有分级整理好**。它主要花钱在存储、数据工程与治理，而不是算力；规模要等"业务数据盘点"后专项定。这一层也让"业务数据分析与整理"第一次有了工程化的落点。

P37 · 内容·公共设施与软件底座

- **软件栈**：MindIE / vLLM-Ascend（昇腾配套推理栈，主力组件开源 ¥0）〔01-Q22〕
- **四项运行时机制**：continuous batching（并发吞吐）、prefix caching + chunked prefill（长上下文 / 冷加载首包）、KV 换出（省卡）、三本账监控（容量/带宽/算力）〔01-§5.3〕
- **设施**：机房 5 柜 / 25~40m²、双路电力 ~100kW、UPS、空调 N+1、风冷（细账见 P41–P42）
- **安全与合规**：网闸/内网闭环、网关审计、量化校准与安全合规软件（计入软件费）

备注（约 30 秒）：这一页是“厂房与水电”。在线推理、训练调优、数据底座三层都跑在这套公共底座上——这也是“基础设施”的题中之义：**共用一份机房电力网络运维，而不是三套各建**。每项的“为什么这个量”在第五部分理由里逐条推导。

P38 • 理由•硬件①：为什么是约 100 张卡（正面推导）

推导链（不是拍数）：

1. **需求** → 峰值解码 ~700 路（P26–P27 漏斗）
2. **两池拆分**：短问答走 27B（轻卡省电）→ 交互池；长上下文/吞吐走 Flash-Next（重卡省带宽）→ 重负载池
3. **交互池 16 卡**：~270 路峰值解码 ÷ 单卡可用并发 ≈ 16（27B × 8 × TP2）
4. **重负载池 80 卡**：570~700 路中“长上下文 + 吞吐”部分 ÷ Flash 单卡服务能力 ≈ 80（Flash × 10 × TP8）
5. **16 + 80 = 96 ≈ 100 张**；单台 8 卡 → **12 台 8 卡机**

为什么“双模型分池”而不是单旗舰：27B 负责轻问答省 14 卡、Flash 负责重负载——各自在正确的问题上省钱〔01-Q20 备选对照〕；旗舰 Max 成本过高不采用。

为什么量化省一半卡：KV INT8→INT4、权重 W8A8，直接压小“每路带宽/每路 KV”两大成本来源〔01-§3〕。

备注（约 60 秒）：这一页是回应“为什么约 100 张卡”的正式推导——把 P26–P27 的峰值路数，分别送进两个池，16+80=96。三个“为什么”一句话：**分池让轻活不占重卡、量化让每路成本减半、口径五轮让需求不虚高**。这套推导每一步都在 01 报告里有账〔01-§5〕。

P39 • 理由•硬件②：为什么是“12 台 + 外围”这套组成

- **机器粒度**：8 卡整机（不是散卡）——供电/散热/互联成组、单台故障影响面可控
- **组网**：TP8/TP2 组内高速互联（长上下文 1M 的跨卡协同依赖它）；机间网络满足推理流量

- **存储**：模型权重 + KV 换出（B 档）+ 数据底座共用——大容量、分热温冷
- **网关与安全机**：路由/配额/审计的落点，1~2 台即可
- **备件与冗余**：备 1 台整机量级——保障"产线"可用性（运维内容见 P43）

备注（约 30 秒）：96 卡不是 96 张裸卡堆在一起，而是 **12 台 8 卡机 + 组网 + 存储 + 网关 + 备件** 这套工程组成。单台能力 × 台数 → 容量；冗余与备件 → 可用性。这套组成的价值在 01 报告成本里对应"硬件 ¥660~845 万"〔01-§6〕。

P40 • 理由•软件：为什么是这几件，各解哪个问题

软件/机制	解决什么需求问题
MindIE / vLLM-Ascend	昇腾国产卡的正确打开方式（不用闭门造车）
continuous batching	几百上千会话同时在线，不排队等死 → 吞吐
prefix caching + chunked prefill	1M 长文档重复前缀复用 + 冷加载首包 ~11s → 降到 <1s
KV 量化 + 换出（INT4/offload）	每路 KV 减半、B 档三级驻留 → 省卡（96 vs 200）
量化校准 + 安全合规	精度不失控 + 数据/审计合规
三本账监控	容量/带宽/算力实时看，负载画像校准 POC 的依据

软件费 ¥60~150 万构成：主力推理栈 ¥0（开源）+ 量化校准 + 安全合规 + 集成实施。

备注（约 40 秒）：软件钱花在哪、为什么每一件都对应一个真问题——尤其"prefix caching + KV 量化换出"这两件，是**1M 长上下文能在 96 卡上跑、而不是 200 卡**的直接原因（P34）。软件不是成本项，是省卡的关键杠杆。

P41 • 理由•电力：为什么是双路 ~100kW（由设备清单推出）

1. **单卡 TDP**：Atlas 300I A2 ≈ **350W**（64GB 版）
2. **整机 + 外围分摊**：96 卡全上约 33.6kW（卡面），加整机/网络/存储/网关/制冷损耗 → **IT 平均 ~52kW**
3. **双路供电**：380V 各 ~100kW——一路检修/故障另一路顶着（可用性）
4. **PUE 1.4** → 年耗电 ≈ 64 万度 ≈ **¥45 万/年**
5. 预留：训练调优/数据底座增量接入时，按弹性复核扩容（POC 期先测实际水位）

备注（约 30 秒）：电力不是拍脑袋的"好像要不少电"——从**单卡 350W × 96** 起算，分摊损耗得 IT ~52kW，双路 ~100kW 是给"一路坏了还能跑"留的冗余〔01-§6/Q22〕。训练区若上，电力在这个基数上做弹性复核即可，机房配电一次做够。

P42 • 理由•机房：为什么是 5 柜 / 25~40m² / 风冷无液冷

结论	推导
12 台 8 卡机 + 网络/存储/网关	单柜约 2~3 台机（按供电/散热密度）→ 约 5 柜
25~40m ²	5 柜 + 通道 + 运维空间；新建微模块或 利旧 均可
UPS 100kVA	对齐 ~100kW 双路，市电掉电时撑到安全关停
2×25kW 空调 N+1	显式 N+1，坏一台不升温——产线不能因空调停机
风冷，无液冷	单柜密度推理规模下风冷足够；液冷是更大密度才需要的复杂度

备注（约 30 秒）：机房每一项都能从"12 台 8 卡机 + 外围"推出来——**柜数由机器与供电密度出，面积由柜数与运维空间出，空调 N+1 由"产线不停"的要求出，风冷够用就不上液冷。**还保留了利旧选项，新建/利旧两档费用在 01 报告里〔01-Q22〕。

P43 • 理由•运维：为什么是这些内容、对应什么人力

自运维（企业内）的事项清单：

1. **容量与健康**：三本账监控、负载画像校准（POC 起持续做）
2. **模型与版本**：基座升级、量化校准、专用模型版本管理与上线审批（与训练区衔接）
3. **系统运维**：升级、补丁、告警、故障响应（含 8 卡整机级备件轮换）
4. **安全与合规**：网关审计、数据分级授权复核、内网闭环巡检
5. **人**：对应年运维人力 **¥30~60 万**——约 2~4 人规模的能力岗（含外包弹性）

数字可复核示例（"快从哪来"可审计）：业界 113 tok/s = 带宽（3.35TB/s）÷ 激活字节（37GB）× MTP（1.25）——物理账 × 产品档位 × 供给 × 实测，四层可见，任何厂商宣传都按这个拆〔01-Q26〕。

备注（约 40 秒）：运维不是"找个网管看机器"，而是**模型与数据时代的能力岗**——会看三本账、会做量化校准、会把关模型版本、能对厂商说法做"113 拆解"式复核。¥30~60 万对应的是这支小队伍，而不是外包甩手掌柜。这也是"Know-how 留在企业内"的真正含义。

P44 • 经济总账：把每一项理由串成一张表

构成	推导依据（见 P38–P43）	金额（估算•待询价）
硬件	96 卡·12 台 8 卡机 + 网络/存储/网关/备件	¥660~845 万
软件	国产推理栈 ¥0 + 量化校准/安全合规/集成	¥60~150 万
机房	新建微模块 5 柜 / 利旧	¥70~105 万 / ¥30~50 万
一次性 CapEx		¥850~1100 万
年 OpEx	电 45 + 维保 20-30 + 软件 10-20 + 运维人力 30-60 + 杂项 5	¥110~160 万

注：本表 CapEx / OpEx 为**估算•待询价**（口径 P03）；硬件下界依赖集采折扣、偏乐观〔01-Q27〕，询价后回填。

- **年化人均**：3 年口径 ¥1000~1300/人/年；5 年 ¥700~930
- 与"订阅制"只作背景一句：公有云订阅 3 年约 ¥3600~6000 万，本方案约 ¥1200~1550 万——**按产能投资，不是按 token 收租**〔01-§6.1〕（本期理由重心在构成推导，此处点到为止）

备注（约 40 秒）：总账不是凭空一张表——**P38–P43 每一项"为什么是这个量"**，在这里乘以单价就得到这张账。850~1100 万一口气投下去，换来的是产线、车间、原料库、厂房四样东西，且三年运营下来人均成本反而低于持续订阅。训练/数据增量未计入本期——这正是收口页要建议的"专项"。

P45 • 引擎 B • 总览：机载专用模型训练（3B → Atlas 200I A2）

一句话：企业产品（机载设备）要"内嵌 AI"——专用模型在企业内训好，**量化后烧进国产嵌入式 GPU 模块**（昇腾 Atlas 200I A2），作为机载设备里的电子模块随装机部署。

- 需求锚点〔02〕：**10 部门各一套**独立训练环境（形态 A）；保密分区强制
- 模型目标〔02-§2〕：**3B 级小语言模型**，任务以**图像为主 / 可含水声信号**
- 本期承诺：**一张训练卡不买**；先用 1 个部门 POC 验证两道门禁（P55）
- 全部金额**估算、待询价**，独立于本期在线推理账（P44 不含）

备注（约 30 秒）：本页起为**引擎 B（机载专用模型训练）**——它与引擎 A 的边界见 P46，部署目标反推见 P47，规模见 P49，保密分区见 P50，成本见 P51，风险见 P52，与引擎 A/底

座关系见 P53；统一推进 P54，指标收口 P55，汇报收口 P56。引擎 B 金额均为**估算待询价、本期不采购**，POC 先行。

P46 • 引擎 B • 边界：造/烧模型 ≠ 服务模型（两引擎、两条生产链）

维度	在线推理（01 号）	机载专用模型训练（02 号）
干什么	内网服务模型，多人并发问答/编码/报告	造/调专用模型，训完烧进机载模块
模型去向	数据中心 96 卡（300I A2）跑	机载模块（昇腾 Atlas 200I A2）烧录
硬件	推理卡 300I A2（PCIe）	训练卡 910B 系（HCCS）+ 烧录/验证台
保密	数据不出域（内网闭环）	一密一网、10 个物理隔离封闭域
账	本期 CapEx ¥850~1100 万	独立专项（估算，POC 先行）

备注（约 30 秒）：两类硬件、软件（MindIE 推理栈 vs MindSpeed 训练栈）、保密要求都不同，**分开立项、不混账**，才不会把两块大数叠在一张预算里吓到决策层。

P47 • 引擎 B • 部署目标反推：先定“模型装进什么”

- 机载芯片已定：昇腾 Atlas 200I A2（端侧 NPU 模块）
- 目标模型已定：3B 级小语言模型，可融合图像/水声编码
- 推论：模型体量由模块内存/算力/功耗封顶 → 训练走中小算力 + 重数据/重转换链，而非大参数量预训练
- 门禁：3B + 编码器能否装入，取决于模块内存实测（datasheet 复核 + 模块样机先导试验——见 P52）
- 原理（上限为何由内存定）：装得下 = 量化权重（INT4 3B ≈ 1.52GB / INT8 ≈ 34GB，估算）+ 图像/水声编码器 + 运行缓冲 < 模块可用内存；**内存决定“装不装得下”，算力只决定“跑多快”** → 门禁 = 内存实测（P52）

备注（约 30 秒）：任何“专用模型”需求先过一问——**装进什么**。模块内存决定模型上限，模型上限决定训练环境规模。顺序反了，就会买错训练卡。

P48 • 引擎 B • 单套训练环境：六件套闭环

#	组成	说明
1	训练算力	昇腾训练整机（910B 系，如 Atlas 800T A2），3B 级单台即可
2	训练软件栈	CANN + torch_npu + MindSpeed/ModelLink（与在线推理 MindIE 栈是两套）
3	数据环境	图像/视频标注 + 水声（→时频图）任务数据，密级管理
4	QAT 与量化转换	量化感知训练 → INT4/INT8 → 导出 200I A2 可加载格式（ 上机的关键链 ）
5	烧录与真机验证台	接模块工装：精度对照、时序、功耗、温箱回归
6	版本管理	数据集/模型/量化/烧录批次留痕，支撑型号追溯

- ▶ **为什么单套能扛 3B（指标=满足部门训练节拍）**：3B 全参 SFT 的 BF16 权重≈6GB，单张 64GB 训练卡即可承载（含梯度/优化器，估算；LoRA 更省）；整机多卡是给**部门多人并发 + 更大模型**留的余量，非必须

备注（约 30 秒）：机载交付单元不是“模型权重”，而是“**可烧录、可回归的量化制品**”。六件套缺一件，训出来的模型都到不了机上。

P49 • 引擎 B • 规模：10 部门各一套（两档测算）

档位	单套组成	单套（估算·待询价）	×10（估算·待询价）
标准档	8×910B 训练整机 + 数据/转换/烧录验证台 + 独立柜与配电	¥150~250 万	¥1500~2500 万
轻量档	24 卡训练小机 + 配套（部门+3 人/数据量小时选）	¥60~120 万	¥600~1200 万

- 企业口径：**10 部门各一套**（形态 A 定案）——因**保密分区强制**，各套物理隔离
- 形态 B（集中算力池 + 工位）仅在保密办确认“允许共享/非密”的部门采用（备选）
- 单价**估算待询价**；先按部门实际人数与数据量定档，不必全顶格标准档
- ▶ **为什么两档都算“满足 10 部门各一套”**：3B 属中小负载——单卡即可“训得动”，档位只随部门**人数/数据量**定（标准档=多人排队不等待，轻量档=1~3 人小团队）；可验收指标=训练利用率不闲置、人不排队死等（估算）

备注（约 40 秒）：这是训练区最大的一笔数，也是高层最关心的一页。请各位注意两件事：
 ①**金额是估算待询价**；②**本期一张卡都不买**——先用 P55 的小 POC 验证，再决定按哪个档

铺。

P50 • 引擎 B • 保密分区：三区十域

- **Z2 受控摆渡区**（唯一进出口）：外部数据/软件/权重 经白名单登记、杀毒、哈希校验、密级标识后**单向导入**
- **Z3 涉密训练区 = 10 个物理隔离封闭域**（每部门一套：训练机+数据+转换+烧录验证台，独立机柜/配电），彼此及对外**无网络连接**
- **Z4 监管区**：系统管理员 / 安全保密管理员 / 审计管理员 **三员分立**；日志只读镜像汇聚
- 模型/数据出区：**审批 + 密级标识 + 双人复核** → 装机交付；USB/光驱受控、禁私带介质

备注（约 40 秒）：保密分区的**架构层方案**（三区十域）已出，细则（密级界定、三员岗位、适用条款）由保密办审定。一个提示：若保密办界定多数部门**同密级**，可降级为“分域分区、非网级隔离”，布点与成本下调——所以密级界定是 P52 待确认项之首。

P51 • 引擎 B • 成本与分期（估算待询价）

阶段	内容	一次性规模（估算·待询价）
专项 POC	选 1 个部门跑通“3B 训—量—烧—验 + 保密分区落地”	¥150~250 万（一台训练机+数据台）
分批铺开	按两档铺 10 部门各一套	标准 ¥1500~2500 万 / 轻量 ¥600~1200 万
二期扩容	随型号需求 + 数据量实测	专项测算

- **人力增量**：训练算法 + 数据/验证 + 保密三员（估算 ¥150~250 万/年量级，另计）
- **配电/机房**：训练区独立分区/配电（10 套 IT 6080kW 量级），与在线推理分开评估
- **POC 为何能验指标**：两门禁——“3B 装入 200I A2”（体积/时延/时序/功耗）只能真机测、“保密分区”只能实体三员/摆渡预检——均不可纯纸面推导，故先用 1 部门小 POC 换可验收数据

备注（约 30 秒）：训练区是**独立专项**，金额不进 P44 的本期账。先花一个小 POC（150~250 万级）验证两门禁，达标再立专项、分批铺——与在线推理“POC 先行再上量”是同一纪律。

P52 • 引擎 B • 风险与待确认

待确认/待实测：

#	项	影响
1	Atlas 200I A2 基础版 vs Ind 高可靠版 + 内存容量 (datasheet)	3B + 编码器能否装入
2	3B 装入模块实测 (权重大小/推理速度/时序/功耗)	方案成立性
3	保密办对部门密级界定 (可否同密级降级"分域分区")	布点与成本
4	训练整机/小机与配套单价 (询价)	成本转实测

主要风险：3B+编码器超模块 → 样机先导压测，必要时降编码器/INT4/蒸馏；图像/水声数据不足 → 先建 1 部门数据集；保密合规落地慢 → 保密办前置。


备注 (约 30 秒)：P52 是训练区的"诚实页"——**模块内存没实测前，一切模型体量数字都是假设**；这也是为什么只建议先做小 POC，而不是先批大采购。

P53 • 引擎 B • 与引擎 A 及公共底座的关系

- **独立采购：**训练卡 (910B 系) ≠ 推理卡 (300I A2)，两类清单分开
- **独立分区：**训练区涉密封闭域 (Z3) 与在线推理内网区物理隔离，不共用
- **数据底座 (C) 联动：**任务数据线 (图像/水声标注) 优先服务训练专项——C 区是训练区的"原料厂"
- **本期公共设施：**机房/电力按在线推理建，给训练区留扩容口子但不作承诺

备注 (约 20 秒)：两者共用的是"企业建 AI 能力的决心与方法"，硬件、软件、保密、账目都分开——边界清楚，才能各自算得清、审得明。

P54 • 统一推进节奏与风险 (引擎 A+B 一体)



关键风险与缓解（指向 POC，不赌）〔01-§7〕：

风险	缓解
硬件价格波动（±30%）	多源询价、POC 期锁价
KV-INT4 精度损失	POC 跑 SWE-bench 类基准；不达标退 INT8（+80 卡）
占空比/上下文分布偏差（卡数 ±20%）	POC 用 IDE 插件 + 会议日历采样两周实测校准
软件 offload 成熟度	A' 档不依赖 offload，B 档等成熟再演进
Flash-Next 昇腾软件栈适配（Qwen4 新架构算子 / EP-TP / KV 量化 / 1M；2026-08-26 才开源）	POC 首站以昇腾官方栈跑同基准；不达标退 KV INT8 或暂缓重负载扩卡，27B 多副本兜底
1M 冷加载首包 ~11s	仓库上下文预热 + 错峰准入

备注（约 50 秒）：落地从 150~200 万、3 个月的 POC 开始，而不是一步 96 卡。POC 用真实负载验证四个数（占空比、上下文分布、INT4 精度、报告/数据任务频率），达标再进二期。所有风险都有缓解、都指向 POC——这是让"96 卡、850~1100 万"从测算变成可执行交付的唯一路径。

P55 • 指标收口：A/B 三层验收总表 + 放行矩阵

收口规则：每个指标带 5 属性——目标 / 统计口径 / 测试条件 / 证据 / 不达标回退；A·在线按 P95 收口，B·机载按"平台级 + 任务级、额定工况最坏值"收口。

层	引擎 A • 在线	引擎 B • 机载	证据	不达标回退
业务体验	首包≤3s(P95-warm)；解码≥60(P95)；Agent 轮≤30s；报告排队≤10min	任务级：正确率≥现状基线 且 ≥上界 90%（生成 85%）【默认】；端到端时延按任务级 S1≤200ms/S2≤5s(上限 15s)/S3 分钟级【默认】	真负载 / 固定回放集	预热、退 INT8、增数据/蒸馏
平台容量	占空比/上下文分布/报告频率实测（假设 15~35% 待校准）	3B INT4 体积≤模块可用内存；推理速度/时序/功耗	POC 两周采样 / 模块样机	按实测重算卡数（±20%）
采购放行	Flash-Next 昇腾栈达标（算子/KV/1M）	装得进+跑得动+精度达标，且保密预检三件证据（P50）	POC 验收门	退 INT8/暂缓扩卡/缩小试点

注：上表默认值均为【建议，待业务/保密办书面校准】；INT4 相对 BF16 量化退化 $\leq 2pp$ （分类类）为经验默认。在线 SLA 阶梯见 P13。

放行逻辑：POC 达标 → 提交正式采购（届时按“基准档 + 最大需求上界”两版）；部分达标 → 只扩试点或走“回退”列；主门禁（采购放行行）不达标 → 不采购、回方案层重申。

备注（约 25 秒）：这张页把散在各页的 SLA 收成**一张总表**，三层各有一个 owner（业务体验 = 业务/型号总师、平台容量 = 基础设施组、采购放行 = 采购 + 保密办）。POC 达标与否，用这张表的“回退”列说话，不靠感觉。

P56 • 汇报收口：三句话 + 建议下一步

汇报要点（三句话）：

1. 企业 AI 基建 = **一份整体方案**：引擎 A·在线推理（本期落地）+ 引擎 B·机载专用模型训练（POC 先行）+ 数据底座 C——把“用 AI、造 AI、装 AI”的能力都沉淀在企业内部
2. 每一块的量都是从需求推出来的（A：96 卡，从人时漏斗；B：10 部门各一套，从机载模块反推）——预算可追溯、POC 先行再上量
3. 数据不出域 / 密级分区 / 权属自持——一次性投入买的是长期自持的能力

全口径一览（估算、待询价；B/C 本期不并表，是否并表交审议）：

构成	口径	金额（估算·待询价）
引擎 A·在线推理（本期）	CapEx / 年 OpEx	¥8504400 万 / ¥110160 万·年
引擎 B·机载训练（POC 先行、独立立项）	1 部门 POC → 10 部门	POC ¥150250 万 → 标准 ¥15002500 万 / 轻量 ¥600~1200 万
C·数据与知识底座	存储/治理为主，随盘点立项	专项测算（P36）

注：两引擎共用公共设施（机房/电力/网络/存储/运维/安全）；引擎 B 与 A 的硬件、软件、密级分区相互独立（P46/P50/P53）。

正式采购 • 最大需求上界（参考，不构成本次批准）：

构成	上界场景	金额（估算·待询价）
引擎 A·在线推理	编码全员 1M 且 KV 全 HBM 硬上档	200 卡，CapEx ¥14001600 万 [01-Q23]

构成	上界场景	金额（估算·待询价）
引擎 B · 机载训练	10 部门全标准档（8×910B）	¥16502750 万（含 POC ¥150250 万）
A+B 上界合计		≈ ¥3000~4400 万量级 〔估算·待询价〕（C 与人力另计）

注：上界仅用于锁预算边界与预留，**不是本次批准金额**。正式采购规模以 POC 实测 + 指标收口（P55）达标后的实际需求定档，届时按“基准档 + 最大需求上界”两版提交。

本次请审议（供审议，非采购）：三项论证启动：

1. 启动**引擎 A · 在线推理一期 POC** 立项论证（16 卡，¥150~200 万，3 个月）
2. 启动**引擎 B · 机载训练 POC**（1 个部门，¥150~250 万估）：验证“3B 装入 Atlas 200I A2 + 保密分区落地”两门禁（P47/P50/P55）
3. 同步开展**业务数据盘点**（C 区）与**保密分区细化**（保密办前置，P50）

备注（约 35 秒，收尾）：今天不请各位拍板采购，只请三项论证启动：①**引擎 A 在线推理一期 POC**；②**引擎 B 机载训练 POC（3B 装得进模块否、保密分区落得地否）**；③**数据盘点与保密细化**。POC 验收按 P55 指标收口表执行，达标后 A、B 各提正式投资方案——届时按“基准档 + 最大需求上界（≈¥3000~4400 万，上表）”两版提交，把预算边界一次讲清。谢谢。