

企业 AI 基础设施建设 方案建议

一个底座，支撑四类企业 AI 需求——产品智能化、产品数据开发、AI 技术研究、AI 办公
在线推理一期 96 卡（约 100 张） · 一次性约 ¥850~1100 万 · 年运营 ¥110~160 万

汇报人 / 2026-09-07

汇报主线

1. **为什么建** —— 企业 AI 需要从 " 零散试点 " 升级为 " 基础设施 "
2. **建成后验收什么** —— 三层能力 + 可验收的 SLA
3. **企业要用 AI 干什么 (四类需求)** —— 需求 → 基础设施诉求
4. **基础设施建什么** —— 在线推理 + 训练调优研究区 + 数据底座
5. **每一组成部分为什么是这个量** —— 从需求推导 (本次汇报的重点)
6. **节奏与风险** —— 分期、POC、风险预防

一句话方案 + 全稿口径

一句话方案：建设**企业 AI 基础设施**——以**在线推理平台**（双池 96 卡，约 100 张）为一期主体，向前预留**专用模型训练调优区与数据与知识底座**，共用一个机房 / 电力 / 网络 / 运维底座。

口径承诺（全稿有效，正文不重复）：

数据类别	口径	状态
金额（CapEx/OpEx）	按 01 报告口径	估算，待询价
卡数（16+80=96）	由需求口径测算	测算，待 POC 校准（±20%）
KV/ 带宽等物理参数	官方 + 假设	假设项待实测
训练调优 / 数据底座规模	本期识别并预留	待专项测算（本稿不估数）
报告状态	定稿	POC 待验证

现状与痛点：今天为什么必须动

-
- **研发侧：**编码 / 调试 / 设计文档的 AI 用量在涨，但受制于公网不稳、速率不确定——真正敢把 " 整仓代码 + 设计文档 " 交给 AI 的很少
 - **办公与管理侧：**问答、管理类报告主要靠人——业务数据散、整理靠手工，AI 帮助有限、质量不可控
 - **共同问题：**数据出境（代码、业务数据在公网服务上）、额度墙（用量一高就受限）、能力无法积累（提示词 / 知识 / 模型 Know-how 都留在外部）

目的总述：从 “零散试点” 到 “基础设施”

把企业 AI 从**单个试用**升级为**一项基础设施**，三层含义：

1. **算力资产**：一次规划、随业务增长平滑扩容，不再每次单点采购
2. **数据资产**：业务数据有序接入、分级、沉淀，成为企业可复用的原料
3. **模型与 Know-how 资产**：专用模型的训练 / 调优经验、评测、运维方法都留在企业内

目的之支撑：四类企业需求共用一张底座

未来企业 AI 的四大用场，都在这张底座上跑：

#	需求	一句话
①	产品智能化转型	企业产品要 " 带 AI" ， 需要专用模型， 能训能调
②	基于 AI 的产品各数据开发	用 AI 批量开发 / 加工产品侧数据与语料
③	AI 技术研究	跟踪、 试验、 评测新模型与新技术
④	AI 办公	业务数据分析与整理、 管理类报告编制、 问答等

目的之红线：数据不出域、合规与权属

- **数据不出域**：研发代码、业务数据、管理材料，全部在企业内网闭环处理（这是私有化建设的首要红线）
- **权属归企业**：基于开源基座训练的领域专用模型，权属、部署、演进完全自主
- **可审计**：AI 网关对 " 谁在什么时间调用了什么、数据流向哪 " 全程留痕——既是内控，也是合规抓手

目的之时点：为什么是现在

- **模型就绪**：千问 3.8（2026-08）——27B 稠密（1M 能力、Apache 2.0 可商用）+ Flash-Next MoE（低成本长上下文），首次在可接受成本内覆盖 " 长上下文研发 + 全员问答 / 报告 "
- **国产卡就绪**：昇腾 Atlas 300I A2（64GB，1.6TB/s）已到推理主力代际，配套 MindIE/vLLM-Ascend 软件栈成熟
- **用量窗口**：各条线 AI 使用量正在爬坡——现在建，爬坡期的每一次使用都在给企业自己积累数据与经验；继续等，用量继续外流、成本难控

目标总览：建成后验收什么

建成后验收**三层能力** + **一套可验收的体验指标**：

能力层	内容
A · 在线推理	研发 1M 长上下文 Agent 环常态化；全员流畅级问答 / 报告
B · 训练调优与研究	专用模型能训能调；AI 研究有实验田
C · 数据与知识底座	业务数据接入—分析整理—分级入库，反哺问答 / 报告 / 训练
体验	一套明确 SLA （ P13 ） —— " 好不好 " 是可验收的句子，不是感觉

目标 A · 在线推理：研发 1M Agent 环 + 全员流畅问答 / 报告

-
- **研发（Agent 环）**：编码、调试、设计文档能放进 **1M 上下文**——整仓代码 + 设计文档一起给 AI，Agent 真正可用
 - **全员（问答 / 报告）**：短问答与报告生成达到 "**流畅级**"（60~80 tok/s，见 P13 标尺）
 - **三类负载错峰共池**：研发白天碎片 + 报告集中段排队填谷，互不挤死

目标 B · 训练调优与研究：专用模型能训能调、研究有实验田

- **产品智能化**：企业产品要内嵌 AI，通用基座不能直接出厂 → 基于开源基座（千问系）在企业内做**领域专用模型的训练与调优**
- **AI 技术研究**：试验、评测新模型 / 新方法需要一个**弹性实验田**（利用率天然波动，与在线推理错峰）
- **目标表述**：不是 " 本期建多大训练集群 "，而是 "**下一批模型能造、能调、能比，接得上在线推理、不堵生产**"—— 规模随专项需求定

目标 C · 数据与知识底座：业务数据能进、能理、能用

- **接入与分析整理**：各业务系统的数据有序接入，做**分级、清洗、分析、整理、入库**（AI 办公场景的核心诉求之一）
- **分级授权**：不同密级的数据服务不同场景，合规边界清晰
- **反哺闭环**：整理后的数据成为三件事的原料——问答 /RAG 的知识来源、管理报告的素材、训练调优的语料

目标：一套可验收的体验标尺（SLA）

感知阶梯（流速 → 体感）：

流速	体感	判断
<20 tok/s	拖沓	不可交付
20~40	勉强	保底
40~60	及格（公有云底部区间）	验收线
60~80	流畅（超阅读极限 ~10 倍）	设计目标
>100	体感无差别	仅批处理受益

四项 SLA 验收〔01-Q25〕：

- 首包（warm）≤ 3s（P95） | 解码 ≥ 60 tok/s（P95） | 研发 Agent 整轮 ≤ 30s | 报告排队 ≤ 10 分钟

主要需求全景：企业用 AI 干什么（四类）

#	需求	落到基础设施
① 产品智能化转型	专用模型训练 / 调优（离线·项目制） + 产品内推理（在线）	B 造调区 + A 推理
② 基于 AI 的产品各数据开发	批量 / 吞吐型数据处理（可排队） + 数据管线	A 推理（吞吐） + C 底座
③ AI 技术研究	弹性训练 / 评测实验田（利用率波动）	B 造调区
④ AI 办公（业务数据分析与整理、管理类报告编制、问答等）	数据分析整理（底座） + 管理报告（吞吐） + 问答（在线 / RAG）	A 推理 + C 底座

需求① · 产品智能化转型：要 " 造 / 调专用模型 "

- **要什么**：企业产品要内嵌 AI 能力——通用模型不能直接出厂（领域不懂、不可控），须在企业内训出 / 调出**领域专用模型**
- **形态**：离线为主、随产品迭代项目制进行；训好上线的产品推理回到在线池
- **工作量特征**：调优（微调 / LoRA ）周期短、量级小可起步；规模化训练按产品线需求单独立项
- **对基础设施的提醒**：本期先保证 " 能训能调、不堵在线推理 "，规模专项测算

需求② · 基于 AI 的产品各数据开发：批量吞吐为主

- **要什么：**用 AI 批量开发 / 加工产品侧的数据、语料、样本（生成、整理、质检、扩量）
- **负载性质：**批量、吞吐型、可排队——不需要抢占式实时，适合排队论调度
- **落在哪：**并入在线推理的“吞吐队列”（与报告类同池），由数据管线承接进出
- **对质量的影响：**这类任务对精度要求分级——能用低精度档跑的就用低档，省卡


需求③ · AI 技术研究：要一个 " 实验田 "

- **要什么**：跟踪开源模型演进、评测替代方案、验证新技术（如投机解码、新量化位宽、国产软件栈）
- **负载性质**：弹性、探索性、利用率波动大——高峰期有、空闲期闲置
- **落在哪**：与训练调优共建一个 " 造 / 调 + 研究区 "，与在线推理错峰共享电力 / 机房 / 网络 / 运维
- **成本策略**：研究负载允许低优先级、可抢占；不为一时的实验去买常年闲置的算力

需求④ · AI 办公：数据分析整理 + 管理报告 + 问答

- 要什么（三层）：
 1. **业务数据分析与整理**——把散在各业务系统的数据分级、清洗、分析、结构化入库（数据底座）
 2. **管理类报告编制**——吞吐型：给素材出报告、给口径出汇总，可排队
 3. **问答**——短问答、快问快答、RAG 式基于企业知识的回答（在线）
- **使用者**：管理 / 职能 / 办公人群，是 " 在线推理 " 里交互问答 + 吞吐报告的主要来源
- **成功标志**：管理者的 " 要个数据 / 要份材料 " 从 " 找人数天 " 变成 "AI 数十分钟、人审校定稿 "


需求 → 基础设施诉求映射（总图）



在线推理量化锚①：人头不是负载，人时才是

- 4000 人 = 研发 2500 + 办公 / 管理 ~1500
- 关键：2500 研发 ≠ 2500 路并发。决定硬件的不是 " 多少人 "，而是 " 同时真正在生成 token 的路数 "
- 研发工时构成 [01-§5.2]：设计 + 编码 ~30-35%、调试 ~25-30%、讨论评审 ~15-20%、试验 ~10-15%、事务 ~10% → AI 活跃占比综合 ~55%
- 占空比谱系 [01-§3]：交互问答 10~25%（人在读） | 研发 Agent 环 30~40%（等工具返回） | 批量吞吐 ~100% 但间歇

在线推理量化锚②：卡数怎么推出来（约 100 张卡）



四层漏斗 [01-\$5.2] :

口径五轮修正, 收敛到 96 卡 [01-\$5.1] :

轮	口径修正	卡数
v1	1000 Agent + 3000 对话	86
v2	对话拆 " 交互 / 吞吐 (报告) "	94
v3	编码全员 1M → 三档	A' 档 72 (编码池)
v4	研发核清 2500 、人时漏斗	110
v5	非研发核清 ~1500	96 (终版) = 重负载 80 + 交互 16

反伪需求判据: 若按 " 全员 1M × 500 路 × 200 tok/s " 最坏值采购 → 算力只要 20 卡、带宽却要 5000 卡——三本账失衡即伪需求 [01-\$4/\$8-6] 。方案只按真实负载买, 不为永远不发生的最坏值买单。


需求小结：已测算 vs 待专项

诉求	状态	说明
A · 在线推理（问答 /Agent 环 / 吞吐）	已测算（01 号报告）	96 卡双池，见 P24–P28
B · 训练调优与研究区	识别 + 架构预留	规模待专项测算（P29）
C · 数据与知识底座	识别 + 按需构建	规模待专项测算（P30）
公共设施（机房 / 电力 / 网络 / 运维）	按一期推理测算	预留训练 / 数据增量扩容复核


总体架构：一张图 + 一个比喻

比喻：企业 AI 基础设施 = 一座 AI 工厂

- 在线推理平台 = 产线（跑日常问答 / 研发环 / 报告，7×24）
- 训练调优与研究区 = 研发车间与实验田（造 / 调专用模型、做实验，按项目开停机）
- 数据与知识底座 = 原料库与质检（业务数据进、分级清洗、按需出料）



内容 · 在线推理平台：双池 96 卡架构



▪ 96 卡 = 12 台 8 卡机: 交互池 16 (8×TP2) + 重负载池 80 (10×TP8)

内容 · AI 网关：路由、配额、审计

- **统一 API**：企业内部所有 AI 应用走一个入口，不再各接各的外部服务
- **三条路由**〔 01-Q21 〕：① 研发一切请求 → 重负载池；② 非研发短输入 → 交互池；③ 报告 / 数据批量任务 → 重负载池排队填谷（ Agent 实时优先）
- **配额与优先级**：研究 / 批量任务低优先级可抢占，生产问答不被挤
- **全量审计**：谁、何时、调了什么、数据流向哪——合规与内控的抓手


内容 · 交互池特写（16 卡）

项	配置	依据
模型	千问 3.8 27B dense （ Apache 2.0 ）	短问答足够、成本低〔 01-Q1 〕
部署	8 卡 × TP2 = 16 卡	交互峰值 ~270 路解码 / ~700 会话
上下文	32K （不是 1M—— 对话甜蜜点）	对话解剖：系统 + 工具 +RAG+ 历史 ≈ 12~20K〔 01-Q15 〕
精度	W8A8 + KV INT8	精度 / 容量平衡
速率	50 tok/s 档	面向问答，不上限保底

内容 · 重负载池特写（80 卡）

项	配置	依据
模型	千问 3.8 Flash-Next MoE （125B 总参 / 6B 激活）	重活成本最优〔01-Q1/Q16〕
部署	10 卡 × TP8 = 80 卡	Agent 环 825 + 快问 550 + 吞吐队列
上下文	1M 能力 （KV INT4）	研发整仓代码 / 设计文档〔01-Q23〕
速率	60~80 tok/s （SLA）	流畅级设计目标〔01-Q25〕
调度	排队填谷：报告 / 数据任务填 agent 碎片谷	负载时间互补〔01-\$5.3〕

内容 · 1M 上下文怎么给：三档选型，起步 A'



为什么 A' 起步: Agent 占空比 35% = 65% 时间会话在 "睡觉" —— **不为睡觉的 KV 买 HBM**。先 A' 上量, 软件成熟后演进 B 档再省卡 [01-\$5.4/Q23]。

内容 · 训练调优与研究区（预留）

本期定位：识别需求 + 预留架构，**规模不做硬测算**（待专项）。

- **起步形态：**LoRA / 全参微调**小集群试点**（比在线推理池小得多，先验证 " 训得动、调得顺 " ）
- **配套能力：**评测基准（SWE-bench 类，与 27B/Flash 同基准对比〔01-Q15 方法〕）、模型版本管理、上线审批
- **弹性调度：**与在线推理**错峰共享机房 / 电力 / 网络 / 运维**；研究负载低优先级可抢占
- **规模策略：**随①产品智能化与③技术研究的需求专项测算后插入，不堵在线推理、不为闲置买单

内容 · 数据与知识底座（预留 / 按需构建）

本期定位：识别需求 + 明确做法，规模随数据盘点专项。

- **接入与整理：**业务系统数据接入 → 分级、清洗、**分析与整理**、结构化入库
- **分级授权：**不同密级数据服务不同场景（如管理报告用经营数据、问答用制度与知识库），合规边界写进授权
- **反哺三件事：**问答 / RAG 的知识来源、管理报告的素材、训练调优的语料
- **依托公共设施：**主要吃存储 + 吞吐推理 + 治理流程，**不是又一座大规模算力池**

内容 · 公共设施与软件底座

- **软件栈：** MindIE / vLLM-Ascend（昇腾配套推理栈，主力组件开源 ¥0）〔 01-Q22 〕
- **四项运行时机制：** continuous batching（并发吞吐）、 prefix caching + chunked prefill（长上下文 / 冷加载首包）、 KV 换出（省卡）、三本账监控（容量 / 带宽 / 算力）〔 01-§5.3 〕
- **设施：** 机房 5 柜 / 25~40m²、双路电力 ~100kW、UPS、空调 N+1、风冷（细账见 P35–P36）
- **安全与合规：** 网闸 / 内网闭环、网关审计、量化校准与安全合规软件（计入软件费）

理由 · 硬件①：为什么是约 100 张卡（正面推导）

推导链（不是拍数）：

1. **需求** → 峰值解码 ~700 路（P20-P21 漏斗）
2. **两池拆分**：短问答走 27B（轻卡省电）→ 交互池；长上下文 / 吞吐走 Flash-Next（重卡省带宽）→ 重负载池
3. **交互池 16 卡**：~270 路峰值解码 ÷ 单卡可用并发 ≈ 16 （ $27B \times 8 \times TP2$ ）
4. **重负载池 80 卡**：~570~700 路中“长上下文 + 吞吐”部分 ÷ Flash 单卡服务能力 ≈ 80 （ $Flash \times 10 \times TP8$ ）
5. **$16 + 80 = 96 \approx 100$ 张**；单台 8 卡 → **12 台 8 卡机**

为什么“双模型分池”而不是单旗舰：27B 负责轻问答省 14 卡、Flash 负责重负载——各自在正确的问题上省钱〔01-Q20 备选对照〕；旗舰 Max 成本过高不采用。

为什么量化省一半卡：KV INT8→INT4、权重 W8A8，直接压小“每路带宽 / 每路 KV”两大成本来源〔01-§3〕。

理由 · 硬件②：为什么是 "12 台 + 外围 " 这套组成

- **机器粒度**：8 卡整机（不是散卡）——供电 / 散热 / 互联成组、单台故障影响面可控
- **组网**：TP8/TP2 组内高速互联（长上下文 1M 的跨卡协同依赖它）；机间网络满足推理流量
- **存储**：模型权重 + KV 换出（B 档）+ 数据底座共用——大容量、分热温冷
- **网关与安全机**：路由 / 配额 / 审计的落点，1~2 台即可
- **备件与冗余**：备 1 台整机量级——保障 " 产线 " 可用性（运维内容见 P37）

理由 · 软件：为什么是这几件，各解哪个问题

软件 / 机制	解决什么需求问题
MindIE / vLLM-Ascend	昇腾国产卡的正确打开方式（不用闭门造车）
continuous batching	几百上千会话同时在线，不排队等死 → 吞吐
prefix caching + chunked prefill	1M 长文档重复前缀复用 + 冷加载首包 ~11s → 降到 <1s
KV 量化 + 换出（INT4/offload）	每路 KV 减半、B 档三级驻留 → 省卡（96 vs 200）
量化校准 + 安全合规	精度不失控 + 数据 / 审计合规
三本账监控	容量 / 带宽 / 算力实时看，负载画像校准 POC 的依据

软件费 ¥60~150 万构成：主力推理栈 ¥0（开源） + 量化校准 + 安全合规 + 集成实施。

理由 · 电力：为什么是双路 ~100kW（由设备清单推出）

-
1. **单卡 TDP**：Atlas 300I A2 $\approx$ **350W**（64GB 版）
 2. **整机 + 外围分摊**：96 卡全上约 33.6kW（卡面），加整机 / 网络 / 存储 / 网关 / 制冷损耗 $\rightarrow$ **IT 平均 ~52kW**
 3. **双路供电**：380V 各 ~100kW——一路检修 / 故障另一路顶着（可用性）
 4. **PUE 1.4** $\rightarrow$ 年耗电 $\approx$ 64 万度 $\approx$ **¥45 万 / 年**
 5. 预留：训练调优 / 数据底座增量接入时，按弹性复核扩容（POC 期先测实际水位）

理由 · 机房：为什么是 5 柜 / 25~40m² / 风冷无液冷

结论	推导
12 台 8 卡机 + 网络 / 存储 / 网关	单柜约 2~3 台机（按供电 / 散热密度）→ 约 5 柜
25~40m²	5 柜 + 通道 + 运维空间；新建微模块或利旧均可
UPS 100kVA	对齐 ~100kW 双路，市电掉电时撑到安全关停
2×25kW 空调 N+1	显式 N+1，坏一台不升温——产线不能因空调停机
风冷，无液冷	单柜密度推理规模下风冷足够；液冷是更大密度才需要的复杂度

理由 · 运维：为什么是这些内容、对应什么人力

自运维（企业内）的事项清单：

1. **容量与健康**：三本账监控、负载画像校准（POC 起持续做）
2. **模型与版本**：基座升级、量化校准、专用模型版本管理与上线审批（与训练区衔接）
3. **系统运维**：升级、补丁、告警、故障响应（含 8 卡整机级备件轮换）
4. **安全与合规**：网关审计、数据分级授权复核、内网闭环巡检
5. **人**：对应年运维人力 **¥30~60 万**——约 2~4 人规模的能力岗（含外包弹性）


数字可复核示例（"快从哪来"可审计）：业界 113 tok/s = 带宽（3.35TB/s）÷ 激活字节（37GB）× MTP（1.25）——物理账 × 产品档位 × 供给 × 实测，四层可见，任何厂商宣传都按这个拆〔01-Q26〕。

经济总账：把每一项理由串成一张表

构成	推导依据 (见 P32–P37)	金额 (估)
硬件	96 卡 · 12 台 8 卡机 + 网络 / 存储 / 网关 / 备件	¥660~845 万
软件	国产推理栈 ¥0 + 量化校准 / 安全合规 / 集成	¥60~150 万
机房	新建微模块 5 柜 / 利旧	¥70~105 万 / ¥30~50 万
一次性 CapEx		¥850~1100 万
年 OpEx	电 45 + 维保 20-30 + 软件 10-20 + 运维人力 30-60 + 杂项 5	¥110~160 万

- 年化人均：3 年口径 ~¥1000~1300/ 人 / 年；5 年 ~¥700~930
- 与 " 订阅制 " 只作背景一句：公有云订阅 3 年约 ¥3600~6000 万，本方案约 ¥1200~1550 万——按产能投资，不是按 token 收租 [01-§6.1] （本期理由重心在构成推导，此处点到为止）

落地节奏与风险预防



关键风险与缓解（指向 POC，不赌）〔01-§7〕：

风险	缓解
硬件价格波动（±30%）	多源询价、POC 期锁价
KV-INT4 精度损失	POC 跑 SWE-bench 类基准；不达标退 INT8（+80 卡）
占空比 / 上下文分布偏差（卡数 ±20%）	POC 用 IDE 插件 + 会议日历采样两周实测校准
软件 offload 成熟度	A' 档不依赖 offload，B 档等成熟再演进
1M 冷加载首包 ~11s	仓库上下文预热 + 错峰准入

汇报收口：三句话 + 建议下一步

汇报要点（三句话）：

1. 企业 AI 要走 "能力沉淀在自己手里" 的路——在线推理先落地，训练调优与数据底座为下一步留好口子
2. 在线推理 "约 100 张卡（96）= 从需求推出来"，预算每一项可追溯、POC 先行再上量
3. 数据不出域、权属自持、运维 Know-how 留在企业——这是一次性投入买的长期资产

建议下一步（供审议，非决议）：

1. 启动**在线推理一期 POC** 立项论证（16 卡，¥150~200 万，3 个月）
2. 开展**训练调优与数据底座的专项需求与规模测算**（覆盖产品智能化、产品数据开发、AI 技术研究、AI 办公四类需求）