

企业 AI 基础设施建设 方案建议

一个底座，支撑四类企业 AI 需求——产品智能化、产品数据开发、AI 技术研究、AI 办公

在线推理一期 96 卡（约 100 张）· 一次性约 ¥850~1100 万 · 年运营 ¥110~160 万

汇报人 / 2026-09-07

汇报主线

1. **为什么建** —— 企业 AI 需要从"零散试点"升级为"基础设施"
2. **建成后验收什么** —— 三层能力 + 可验收的 SLA
3. **企业要用 AI 干什么（四类需求）** —— 需求 → 基础设施诉求
4. **基础设施建什么** —— 在线推理 + 训练调优研究区 + 数据底座
5. **每一组成部分为什么是这个量** —— 从需求推导（本次汇报的重点）
6. **节奏与风险** —— 分期、POC、风险预防

一句话方案 + 全稿口径

一句话方案：建设**企业 AI 基础设施**——引擎 A · **在线推理**（双池 96 卡，约 100 张）为一期落地主体；引擎 B · **机载专用模型训练**（3B 小语言 → 昇腾 Atlas 200I A2 机载模块，10 部门各一套）与**数据与知识底座 C** 为同一方案的组成部分——B 本期不采购、POC 达标后独立立项；三部分共享公共设施、同一张口径表。

口径承诺（全稿有效，正文不重复）：

数据类别	口径	状态
金额（CapEx/OpEx）	引擎 A 按 01 报告口径；引擎 B 按 02 号档位	估算，待询价
卡数（16+80=96）	由需求口径测算	测算，待 POC 校准（±20%）
KV/带宽等物理参数	官方 + 假设	假设项待实测
引擎 B（训练）与 C（数据底座）规模	B：02 号已测算档位（P45–P53）；C：随盘点	估算待询价、POC 先行；本期不并表，全口径见 P56
报告状态	定稿	POC 待验证

现状与痛点：今天为什么必须动

- **研发侧：** 编码/调试/设计文档的 AI 用量在涨，但受制于公网不稳、速率不确定——真正敢把"整仓代码 + 设计文档"交给 AI 的很少
- **办公与管理侧：** 问答、管理类报告主要靠人——业务数据散、整理靠手工，AI 帮助有限、质量不可控
- **共同问题：** 数据出境（代码、业务数据在公网服务上）、额度墙（用量一高就受限）、能力无法积累（提示词/知识/模型 Know-how 都留在外部)

目的总述：从"零散试点"到"基础设施"

把企业 AI 从**单个试用**升级为**一项基础设施**，三层含义：

1. **算力资产**：一次规划、随业务增长平滑扩容，不再每次单点采购
2. **数据资产**：业务数据有序接入、分级、沉淀，成为企业可复用的原料
3. **模型与 Know-how 资产**：专用模型的训练/调优经验、评测、运维方法都留在企业内

目的之支撑：四类企业需求共用一张底座

未来企业 AI 的四大用场，都在这张底座上跑：

#	需求	一句话
①	产品智能化转型	企业产品要"带 AI"，需要专用模型，能训能调
②	基于 AI 的产品各数据开发	用 AI 批量开发/加工产品侧数据与语料
③	AI 技术研究	跟踪、试验、评测新模型与新技术
④	AI 办公	业务数据分析与整理、管理类报告编制、问答等

目的之红线：数据不出域、合规与权属

- **数据不出域**：研发代码、业务数据、管理材料，全部在企业内网闭环处理（这是私有化建设的首要红线）
- **权属归企业**：基于开源基座训练的领域专用模型，权属、部署、演进完全自主
- **可审计**：AI 网关对“谁在什么时间调用了什么、数据流向哪”全程留痕——既是内控，也是合规抓手

目的之时点：为什么是现在

- **模型就绪**：千问 3.8 (2026-08) ——27B 稠密 (Apache 2.0 可商用；原生 262K 上下文，官方支持外推至 1M) + Flash-Next MoE (官方宣传支持 1M 上下文、低成本)，首次在可接受成本内覆盖"长上下文研发 + 全员问答/报告"
- **国产卡就绪**：昇腾 Atlas 300I A2 (64GB, 1.6TB/s) 已到推理主力代际；软件栈成熟度**分层**——27B 已获昇腾 Day0 适配，Flash-Next (Qwen4 预览架构，2026-08 下旬开源) 昇腾侧算子/KV 量化/1M 支持仍在演进，**须 POC 首站验证** (见 P54)
- **用量窗口**：各条线 AI 使用量正在爬坡——现在建，爬坡期的每一次使用都在给企业自己积累数据与经验；继续等，用量继续外流、成本难控

目标总览：建成后验收什么

建成后验收**三层能力 + 一套可验收的体验指标**：

能力层	内容
A · 在线推理	研发 1M 长上下文 Agent 环常态化；全员流畅级问答/报告
B · 训练调优与研究	专用模型能训能调；AI 研究有实验田
C · 数据与知识底座	业务数据接入—分析整理—分级入库，反哺问答/报告/训练
体验	一套明确 SLA（P13）——"好不好"是可验收的句子，不是感觉

目标 A · 在线推理：研发 1M Agent 环 + 全员流畅问答/报告

- **研发 (Agent 环)**：编码、调试、设计文档能放进 **1M 上下文**——整仓代码 + 设计文档一起给 AI, Agent 真正可用
- **全员 (问答/报告)**：短问答与报告生成达到"**流畅级**" (60~80 tok/s, 见 P13 标尺)
- **三类负载错峰共池**：研发白天碎片 + 报告集中段排队填谷, 互不挤死

目标 B · 训练调优与研究：专用模型能训能调、研究有实验田

- **产品智能化**：企业产品要内嵌 AI，通用基座不能直接出厂 → 基于开源基座（千问系）在企业内做**领域专用模型的训练与调优**
- **AI 技术研究**：试验、评测新模型/新方法需要一个**弹性实验田**（利用率天然波动，与在线推理错峰）
- **目标表述**：不是“本期建多大训练集群”，而是“**下一批机载专用模型能造、能调、能烧、能验**”——专项已出（02 号：10 部门各一套训练环境，见 P35），**本期仅预留不采购**

目标 C · 数据与知识底座：业务数据能进、能理、能用

- **接入与分析整理**：各业务系统的数据有序接入，做**分级、清洗、分析、整理、入库**（AI 办公场景的核心诉求之一）
- **分级授权**：不同密级的数据服务不同场景，合规边界清晰
- **反哺闭环**：整理后的数据成为三件事的原料——问答/RAG 的知识来源、管理报告的素材、训练调优的语料

目标：一套可验收的体验标尺（SLA）

感知阶梯（流速 → 体感）：

流速	体感	判断
<20 tok/s	拖沓	不可交付
20~40	勉强	保底
40~60	及格（公有云底部区间）	验收线
60~80	流畅（超阅读极限 ~10 倍）	设计目标
>100	体感无差别	仅批处理受益

四项 SLA 验收〔01-Q25〕：

- 首包（warm） ≤ 3s（P95） | 解码 ≥ 60 tok/s（P95） | 研发 Agent 整轮 ≤ 30s | 报告排队 ≤ 10 分钟

指标认知① · 输出速率由什么决定 + 人的期望

- **物理公式**：每生成 1 token 要把全部权重读一遍 → 单路速率 $\approx$ 带宽 $\div$ 每步权重字节 $\times$ 每步产出 token
 - 27B INT8: $1.6\text{TB/s} \div 28\text{GB} \approx 57\sim 59$ 上限 → 工程取 ~ 50 [01-Q30]
- **四条加速路（不靠并发）**：量化 INT4（字节 $\div 2$ ） / MTP 投机（ $\times 1.3\sim 2.5$ ） / 2 卡 TP（每卡 $\div 2$ ） / MoE 小激活（只读被路由专家）
- **人的期望（感知阶梯）**：<20 拖沓 | 20~40 勉强 | 40~60 及格 | **60~80 流畅（阅读极限 5~8 的 ~ 10 倍）** | >100 无感（仅批处理受益）
- 编码 2K patch: @50 tok/s $\approx$ 40s 可接受; @20 tok/s $\approx$ 100s 烦躁

指标认知② · 并发数怎么定 + 人的期望

- **"并发"三层语义**：会话驻留（只占显存=KV）→ 解码路数（占带宽+算力）→ 硬件 batch GEMM（每步一次）
- **真正花钱的是"解码路数" $\approx$ 会话 $\times$ 占空比**：人在读 / 等工具时模型在歇——对话占空比 10~25%、Agent 30~40%
- **两堵墙**：容量墙 = KV 池 $\div$ 人均占用；带宽墙 = 同时解码路数 $\times$ 每步 KV 读取
- **人头 $\neq$ 并发**：2500 研发 $\neq$ 2500 路并发（后文"人时漏斗"由此把卡数推到 96）
- **人的期望**：并发承诺的是"不排队、峰值不掉速"，不是"人头数=并发数"

指标认知③ · 上下文长度怎么给 + 人的期望

- **模型能力 ≠ 服务配置**：262K / 1M 是"模型能力"；给多少人开、开多长是**容量账**（KV 池 ÷ 每 token 占用）
- **对话 32K 甜蜜点**：解剖 = 系统 2~4K + 工具 1~2K + RAG 2~8K + 历史 8K ≈ 12~20K，留 ~50% 余量
- **1M 是"能开"不是"人人常年挂 1M"**：一条 1M 会话占的 KV，可挤走大量短会话（28GB 权重之外 1M≈120GB）
- **人的期望**：别按模型宣称值给全员开窗——按真实流量画像裁剪上下文预算，才是产品参数

指标认知④ · 首 token / 首包延迟由什么决定 + 人的期望

- **首 token 时延 (TTFT) $\approx$ prefill 计算 + 排队**：长输入里 prefill 是大头 (1M prefill 秒~十几秒级)
- **冷/热分账**：冷载 (无缓存) 1M $\approx$ 11s/实例 (物理)；warm 增量 (前缀命中) <1s [01-Q25]
- **首包 = 流式第一批到屏 = TTFT + 网络/渲染**：与 TTFT 一并看，别只看其一
- **SLA**：warm $\leq$ 3s (P95)；cold $\leq$ 20s (P95 上限，常态经预热回 <3s)
- **人的期望**：warm 3s 内"没感觉在等"；超 ~10s 用户认为卡死——故 1M 场景 TTFT 比流速更敏感

指标认知⑤ · 训练与推理：为什么是两类卡

- **推理 = 前向，瓶颈"带宽"**：每 token 只把权重读一遍，算力几乎闲置 → 推理卡看**带宽 × 容量 × 功耗**（昇腾 300I A2，PCIe 即可）
- **训练 = 反向，瓶颈"算力 + 互联"**：要存激活/梯度、每步全卡同步参数（AllReduce） → 训练卡看**算力密度 × HCCS 高速互联 × 大显存**（昇腾 910B 系）
- **同品牌 ≠ 同卡型**：昇腾三型各司其职——300I A2（推理） / 910B（训练） / 200I A2（端侧推理模块，不可训练）
- **为什么不能拿 96 张推理卡训练**：互联弱、算力密度低、无 scale-up——**训练不是"多买推理卡"，是另一类硬件**（引擎 B 必须另购 910B 的根因）

指标认知⑥ · 一张总表：数字 → 由什么决定 → 人感 → 卡

指标	由什么决定	人的正常期望	对应卡
输出速率	带宽 ÷ 权重字节 × 每步产出	60~80 = 流畅线	推理卡（带宽）
并发数	占空比 + KV/带宽两墙	不排队、峰值不掉速	推理卡 + 容量
上下文长度	KV 容量账（服务配置）	32K 对话、1M 是能力	推理卡显存
首 token/首包	prefill + 排队 + 冷热	warm≤3s / cold≤20s	prefill 算力
训练节拍	算力 + 互联 + HBM	部门"训得动、不排队等"	训练卡（910B）

主要需求全景：企业用 AI 干什么（四类）

#	需求	落到基础设施
① 产品智能化转型	专用模型训练/调优（离线·项目制）+ 产品内推理（在线）	B 造调区 + A 推理
② 基于 AI 的产品各数据开发	批量/吞吐型数据处理（可排队）+ 数据管线	A 推理（吞吐）+ C 底座
③ AI 技术研究	弹性训练/评测实验田（利用率波动）	B 造调区
④ AI 办公（业务数据分析与整理、管理类报告编制、问答等）	数据分析整理（底座）+ 管理报告（吞吐）+ 问答（在线/RAG）	A 推理 + C 底座

需求① · 产品智能化转型：造/调"装进机载设备的专用模型"

- **要什么：**企业产品（机载设备）内嵌 AI——部署形态已锚定 = **国产嵌入式 GPU 模块（昇腾 Atlas 200I A2）**，目标 **3B 级小语言模型、任务以图像为主 / 可含水声信号**〔02-§2〕
- **训练形态：**不是数据中心"服务模型"，而是"**训—量(QAT)—转—烧—验**"闭环——训完量化烧进模块；训练区与在线推理**分域**（涉密隔离）〔02-§3/§7〕
- **规模口径：**专项已出（02 号）——**10 部门各一套**训练环境（形态 A · 保密分区强制）；单套 ¥150~250 万（标准）/¥60~120 万（轻量）**估算待询价、独立于本期 96 卡采购**〔02-§4〕
- **本期定位：**训练区**本期不采购**；先由 1 个部门 POC 验证"3B 装入 Atlas 200I A2 + 保密分区落地"，达标后分批铺〔02-§6〕

需求② · 基于 AI 的产品各数据开发：批量吞吐为主

- **要什么：**用 AI 批量开发/加工产品侧的数据、语料、样本（生成、整理、质检、扩量）
- **负载性质：**批量、吞吐型、可排队——不需要抢占式实时，适合排队论调度
- **落在哪：**并入在线推理的"吞吐队列"（与报告类同池），由数据管线承接进出
- **对质量的影响：**这类任务对精度要求分级——能用低精度档跑的就用低档，省卡

需求③ · AI 技术研究：要一个"实验田"

- **要什么：**跟踪开源模型演进、评测替代方案、验证新技术（如投机解码、新量化位宽、国产软件栈）
- **负载性质：**弹性、探索性、利用率波动大——高峰期有、空闲期闲置
- **落在哪：**研究/评测多属非涉密 → 依托 02 号训练区预留的弹性算力与在线池低谷错峰；涉密实验进密闭训练域（02-§7）
- **成本策略：**研究负载允许低优先级、可抢占；不为一时的实验去买常年闲置的算力

需求④ · AI 办公：数据分析整理 + 管理报告 + 问答


- 要什么（三层）：

1. **业务数据分析与整理**——把散在各业务系统的数据分级、清洗、分析、结构化入库（数据底座）
2. **管理类报告编制**——吞吐型：给素材出报告、给口径出汇总，可排队
3. **问答**——短问答、快问快答、RAG 式基于企业知识的回答（在线）

- **使用者**：管理/职能/办公人群，是"在线推理"里交互问答 + 吞吐报告的主要来源

- **成功标志**：管理者的"要个数据/要份材料"从"找人数天"变成"AI 数十分钟、人审校定稿"


需求 → 基础设施诉求映射（总图）



在线推理量化锚①：人头不是负载，人时才是

- 4000 人 = 研发 2500 + 办公/管理 ~1500
- 关键：2500 研发 ≠ 2500 路并发。决定硬件的不是"多少人"，而是"同时真正在生成 token 的路数"
- 研发工时构成〔01-§5.2〕：设计+编码 ~30-35%、调试 ~25-30%、讨论评审 ~15-20%、试验 ~10-15%、事务 ~10% → **AI 活跃占比综合 ~55%**
- 占空比谱系〔01-§3〕：交互问答 10~25%（人在读） | 研发 Agent 环 30~40%（等工具返回） | 批量吞吐 ~100% 但间歇

在线推理量化锚②：卡数怎么推出来（约 100 张卡）



四层漏斗 [01-§5.2]：

口径五轮修正，收敛到 96 卡 [01-§5.1]：

轮	口径修正	卡数
v1	1000 Agent + 3000 对话	86
v2	对话拆"交互/吞吐 (报告)"	94
v3	编码全员 1M → 三档	A'档 72 (编码池)
v4	研发核清 2500、人时漏斗	110
v5	非研发核清 ~1500	96 (终版) = 重负载 80 + 交互 16

反伪需求判据：若按"全员 1M × 500 路 × 200 tok/s"最坏值采购 → 算力只要 20 卡、带宽却要 5000 卡——**三本账失衡即伪需求** [01-§4/§8-6]。方案只按真实负载买，不为永远不发生的最坏值买单。


需求小结：已测算 vs 待专项

诉求	状态	说明
A · 在线推理（问答/Agent环/吞吐）	已测算（01 号报告）	96 卡双池，见 P30–P34
B · 训练调优与研究区（产品智能化）	已出专项（02 号） · 本期预留不采购	机载专用模型（3B）：10 部门各一套（形态 A · 保密分区），见 P21/P35
C · 数据与知识底座	识别 + 按需构建	通用语料待盘点；任务数据（图像/水声）线并入训练专项（P36）
公共设施（机房/电力/网络/运维）	按一期推理测算	训练区（独立分区/配电）与在线区关系另专项复核（02-§7）


总体架构：一张图 + 一个比喻

比喻：企业 AI 基础设施 = 一座 AI 工厂

- 在线推理平台 = 产线（跑日常问答/研发环/报告，7×24）
- 训练调优与研究区 = 研发车间与实验田（造/调专用模型、做实验，按项目开停机）
- 数据与知识底座 = 原料库与质检（业务数据进、分级清洗、按需出料）



内容·在线推理平台：双池 96 卡架构



- **96 卡 = 12 台 8 卡机**：交互池 16 (8×TP2) + 重负载池 80 (10×TP8)
- **前提**：重负载池以 Flash-Next 为基座——该模型 2026-08-26 才开源，昇腾侧适配（算子 / EP-TP / KV 量化 / 1M）成熟度须 POC 首站验证〔01-v2.2〕

内容·AI 网关：路由、配额、审计

- **统一 API**：企业内部所有 AI 应用走一个入口，不再各接各的外部服务
- **三条路由**〔01-Q21〕：① 研发一切请求 → 重负载池；② 非研发短输入 → 交互池；③ 报告/数据批量任务 → 重负载池排队填谷（Agent 实时优先）
- **配额与优先级**：研究/批量任务低优先级可抢占，生产问答不被挤
- **全量审计**：谁、何时、调了什么、数据流向哪——合规与内控的抓手

内容·交互池特写（16 卡）

项	配置	依据
模型	千问 3.8 27B dense (Apache 2.0)	短问答足够、成本低〔01-Q1〕
部署	8 卡 × TP2 = 16 卡	交互峰值 ~270 路解码 / ~700 会话
上下文	32K (不是 1M——对话甜蜜点)	对话解剖：系统+工具+RAG+历史 ≈12~20K〔01-Q15〕
精度	W8A8 + KV INT8	精度/容量平衡
速率	50 tok/s 档	面向问答，不上限保底


- **为什么 50 tok/s 达标（原理）**：27B INT8 单路上限 ≈ 带宽 ÷ 权重 = 1.6TB/s ÷ ~28GB ≈ 57~59 tok/s〔01-Q30〕；交互取 50 档留余量，峰值 ~270 路由 batch 聚合承载——**达标靠带宽账 × 占空比，不靠堆卡**

内容·重负载池特写（80 卡）

项	配置	依据
模型	千问 3.8 Flash-Next MoE （125B 总参 / 6B 激活）	重活成本最优〔01-Q1/Q16〕
部署	10 实例 × TP8（每实例 8 卡） = 80 卡	Agent 环 825 + 快问 550 + 吞吐队列
上下文	1M 能力 （KV INT4）	研发整仓代码/设计文档〔01-Q23〕
速率	60~80 tok/s（SLA）	流畅级设计目标〔01-Q25〕
调度	排队填谷：报告/数据任务填 agent 碎片谷	负载时间互补〔01-§5.3〕

- **为什么 60~80 tok/s 达标（原理）**：Flash 激活仅 6B → 每 token 权重读取 $\approx 27\text{B}$ 的 $1/4.5$ （ $\div 4.5$ ），叠加 QSA 稀疏读 $\div 8$ 与 KV INT4，单路带宽余量成倍放大〔01 §3 三重减免〕——SLA 60~80 是聚合账下的设计目标，不是超配

内容·1M 上下文怎么给：三档选型，起步 A'



为什么 A' 起步：Agent 占空比 35% = 65% 时间会话在“睡觉”——**不为睡觉的 KV 买 HBM**。先 A' 上量，软件成熟后演进 B 档再省卡〔01-55.4/Q23〕。

内容·训练调优与研究区 (产品智能化 · 依据 02 号专项)

本期定位：专项已出 (02 号 v1.1) ——企业产品 (机载设备) 专用模型 = **3B 级小语言模型**，训后量化烧进 **昇腾 Atlas 200I A2** 机载模块；训练区 = **10 部门各一套**独立环境 (形态 A · 保密分区)。**本期不采购**，先 POC。

- **单套构成：**"训 (910B 系) —QAT/量化—转换—烧录—真机验证"闭环 + 任务数据台；标准档 8×910B 整机 ¥150~250 万/套、轻量档 2~4 卡 ¥60~120 万/套 (估算待询价) [02-§3/§4]
- **保密分区：**10 套为物理隔离封闭训练域，数据/模型经受控摆渡进出，系统/安全保密/审计三员管理 [02-§7]
- **POC (建议先做)：**选 1 个部门跑通"3B 训—烧—验"，先验两件事——**3B 装入 Atlas 200I A2** (显存/速度/时序)、**保密分区与三员落地** [02-§6/§8]
- **与在线推理关系：**训练用昇腾训练卡 (910B 系)，与在线推理 (300I A2) 是**两类采购**；训练区独立分区/配电，与在线 96 卡不混账

内容·数据与知识底座（预留 / 按需构建）

本期定位：识别需求 + 明确做法，规模随数据盘点专项。

- **接入与整理：**业务系统数据接入 → 分级、清洗、**分析与整理**、结构化入库
- **分级授权：**不同密级数据服务不同场景（如管理报告用经营数据、问答用制度与知识库），合规边界写进授权
- **反哺三件事：**问答/RAG 的知识来源、管理报告的素材、训练调优的语料
- **依托公共设施：**主要吃存储 + 吞吐推理 + 治理流程，**不是又一座大规模算力池**

内容·公共设施与软件底座

- **软件栈**: MindIE / vLLM-Ascend (昇腾配套推理栈, 主力组件开源 ¥0) [01-Q22]
- **四项运行时机制**: continuous batching (并发吞吐)、prefix caching + chunked prefill (长上下文 / 冷加载首包)、KV 换出 (省卡)、三本账监控 (容量/带宽/算力) [01-§5.3]
- **设施**: 机房 5 柜 / 25~40m²、双路电力 ~100kW、UPS、空调 N+1、风冷 (细账见 P41–P42)
- **安全与合规**: 网闸/内网闭环、网关审计、量化校准与安全合规软件 (计入软件费)

理由·硬件①：为什么是约 100 张卡（正面推导）

推导链（不是拍数）：

1. **需求** → 峰值解码 ~700 路（P26–P27 漏斗）
2. **两池拆分**：短问答走 27B（轻卡省电）→ 交互池；长上下文/吞吐走 Flash-Next（重卡省带宽）→ 重负载池
3. **交互池 16 卡**：~270 路峰值解码 ÷ 单卡可用并发 ≈ 16 ($27B \times 8 \times TP2$)
4. **重负载池 80 卡**：~570~700 路中"长上下文 + 吞吐"部分 ÷ Flash 单卡服务能力 ≈ 80 ($Flash \times 10 \times TP8$)
5. **$16 + 80 = 96 \approx 100$ 张**；单台 8 卡 → **12 台 8 卡机**

为什么"双模型分池"而不是单旗舰：27B 负责轻问答省 14 卡、Flash 负责重负载——各自在正确的问题上省钱〔01-Q20 备选对照〕；旗舰 Max 成本过高不采用。

为什么量化省一半卡：KV INT8→INT4、权重 W8A8，直接压小"每路带宽/每路 KV"两大成本来源〔01-§3〕。

理由·硬件②：为什么是"12 台 + 外围"这套组成

- **机器粒度**：8 卡整机（不是散卡）——供电/散热/互联成组、单台故障影响面可控
- **组网**：TP8/TP2 组内高速互联（长上下文 1M 的跨卡协同依赖它）；机间网络满足推理流量
- **存储**：模型权重 + KV 换出（B 档）+ 数据底座共用——大容量、分热温冷
- **网关与安全机**：路由/配额/审计的落点，1~2 台即可
- **备件与冗余**：备 1 台整机量级——保障"产线"可用性（运维内容见 P43）

理由·软件：为什么是这几件，各解哪个问题

软件/机制	解决什么需求问题
MindIE / vLLM-Ascend	昇腾国产卡的正确打开方式（不用闭门造车）
continuous batching	几百上千会话同时在线，不排队等死 → 吞吐
prefix caching + chunked prefill	1M 长文档重复前缀复用 + 冷加载首包 ~11s → 降到 <1s
KV 量化 + 换出 (INT4/offload)	每路 KV 减半、B 档三级驻留 → 省卡 (96 vs 200)
量化校准 + 安全合规	精度不失控 + 数据/审计合规
三本账监控	容量/带宽/算力实时看，负载画像校准 POC 的依据

软件费 ¥60~150 万构成：主力推理栈 ¥0（开源）+ 量化校准 + 安全合规 + 集成实施。

理由·电力：为什么是双路 ~100kW（由设备清单推出）

1. **单卡 TDP**：Atlas 300I A2 ≈ **350W**（64GB 版）
2. **整机 + 外围分摊**：96 卡全上约 33.6kW（卡面），加整机/网络/存储/网关/制冷损耗 → **IT 平均 ~52kW**
3. **双路供电**：380V 各 ~100kW——一路检修/故障另一路顶着（可用性）
4. **PUE 1.4** → 年耗电 ≈ 64 万度 ≈ **¥45 万/年**
5. 预留：训练调优/数据底座增量接入时，按弹性复核扩容（POC 期先测实际水位）

理由·机房：为什么是 5 柜 / 25~40m² / 风冷无液冷

结论	推导
12 台 8 卡机 + 网络/存储/网关	单柜约 2~3 台机（按供电/散热密度）→ 约 5 柜
25~40m²	5 柜 + 通道 + 运维空间；新建微模块或 利旧 均可
UPS 100kVA	对齐 ~100kW 双路，市电掉电时撑到安全关停
2×25kW 空调 N+1	显式 N+1，坏一台不升温——产线不能因空调停机
风冷，无液冷	单柜密度推理规模下风冷足够；液冷是更大密度才需要的复杂度

理由·运维：为什么是这些内容、对应什么人力

自运维（企业内）的事项清单：

1. **容量与健康**：三本账监控、负载画像校准（POC 起持续做）
2. **模型与版本**：基座升级、量化校准、专用模型版本管理与上线审批（与训练区衔接）
3. **系统运维**：升级、补丁、告警、故障响应（含 8 卡整机级备件轮换）
4. **安全与合规**：网关审计、数据分级授权复核、内网闭环巡检
5. **人**：对应年运维人力 **¥30~60 万**——约 2~4 人规模的能力岗（含外包弹性）

数字可复核示例（"快从哪来"可审计）：业界 113 tok/s = 带宽 (3.35TB/s) ÷ 激活字节 (37GB) × MTP (1.25) ——物理账 × 产品档位 × 供给 × 实测，四层可见，任何厂商宣传都按这个拆〔01-Q26〕。

经济总账：把每一项理由串成一张表

构成	推导依据（见 P38–P43）	金额（估）
硬件	96 卡·12 台 8 卡机 + 网络/存储/网关/备件	¥660~845 万
软件	国产推理栈 ¥0 + 量化校准/安全合规/集成	¥60~150 万
机房	新建微模块 5 柜 / 利旧	¥70~105 万 / ¥30~50 万
一次性 CapEx		¥850~1100 万
年 OpEx	电 45 + 维保 20-30 + 软件 10-20 + 运维人力 30-60 + 杂项 5	¥110~160 万

- **年化人均**：3 年口径 ~¥1000~1300/人/年；5 年 ~¥700~930
- 与"订阅制"只作背景一句：公有云订阅 3 年约 ¥3600~6000 万，本方案约 ¥1200~1550 万——**按产能投资，不是按 token 收租**〔01-§6.1〕（本期理由重心在构成推导，此处点到为止）

引擎 B · 总览：机载专用模型训练 (3B → Atlas 200I A2)

一句话：企业产品（机载设备）要“内嵌 AI”——专用模型在企业内训好，**量化后烧进国产嵌入式 GPU 模块**（昇腾 Atlas 200I A2），作为机载设备里的电子模块随装机部署。

- 需求锚点〔02〕：**10 部门各一套**独立训练环境（形态 A）；保密分区强制
- 模型目标〔02-§2〕：**3B 级小语言模型**，任务以**图像为主 / 可含水声信号**
- 本期承诺：**一张训练卡不买**；先用 1 个部门 POC 验证两道门禁（P55）
- 全部金额**估算、待询价**，独立于本期在线推理账（P44 不含）

引擎 B · 边界：造/烧模型 ≠ 服务模型（两引擎、两条生产链）

维度	在线推理 (01 号)	机载专用模型训练 (02 号)
干什么	内网服务模型，多人并发问答/编码/报告	造/调专用模型，训完烧进机载模块
模型去向	数据中心 96 卡 (300I A2) 跑	机载模块 (昇腾 Atlas 200I A2) 烧录
硬件	推理卡 300I A2 (PCIe)	训练卡 910B 系 (HCCS) + 烧录/验证台
保密	数据不出域 (内网闭环)	一密一网、10 个物理隔离封闭域
账	本期 CapEx ¥850~1100 万	独立专项 (估算, POC 先行)

引擎 B · 部署目标反推：先定"模型装进什么"

- 机载芯片已定：昇腾 Atlas 200I A2 (端侧 NPU 模块)
- 目标模型已定：3B 级小语言模型，可融合图像/水声编码
- 推论：模型体量由模块内存/算力/功耗封顶 → 训练走中小算力 + 重数据/重转换链，而非大参数量预训练
- 门禁：3B + 编码器能否装入，取决于模块内存实测 (datasheet 复核 + 模块样机先导试验——见 P52)
- 原理 (上限为何由内存定)：装得下 = 量化权重 (INT4 3B $\approx$ 1.5~2GB / INT8 $\approx$ 3~4GB, 估算) + 图像/水声编码器 + 运行缓冲 < 模块可用内存；内存决定"装不装得下"，算力只决定"跑多快" → 门禁 = 内存实测 (P52)

引擎 B · 单套训练环境：六件套闭环

#	组成	说明
1	训练算力	昇腾训练整机（910B 系，如 Atlas 800T A2），3B 级单台即可
2	训练软件栈	CANN + torch_npu + MindSpeed/ModelLink（与在线推理 MindIE 栈是两套）
3	数据环境	图像/视频标注 + 水声（→时频图）任务数据，密级管理
4	QAT 与量化转换	量化感知训练 → INT4/INT8 → 导出 200I A2 可加载格式（ 上机的关键链 ）
5	烧录与真机验证台	接模块工装：精度对照、时序、功耗、温箱回归
6	版本管理	数据集/模型/量化/烧录批次留痕，支撑型号追溯

▀ ▸ **为什么单套能扛 3B（指标=满足部门训练节拍）**：3B 全参 SFT 的 BF16 权重≈6GB，单张 64GB 训练卡即可承载（含梯度/优化器，估算；LoRA 更省）；整机多卡是给**部门多人并发 + 更大模型**留的余量，非必须

引擎 B · 规模：10 部门各一套（两档测算）

档位	单套组成	单套（估）	×10（估）
标准档	8×910B 训练整机 + 数据/转换/烧录验证台 + 独立柜与配电	¥150~250 万	¥1500~2500 万
轻量档	2~4 卡训练小机 + 配套（部门 1~3 人/数据量小时选）	¥60~120 万	¥600~1200 万

- 企业口径：**10 部门各一套**（形态 A 定案）——因**保密分区强制**，各套物理隔离
- 形态 B（集中算力池 + 工位）仅在保密办确认"允许共享/非密"的部门采用（备选）
- 单价**估算待询价**；先按部门实际人数与数据量定档，不必全顶格标准档
- ▸ **为什么两档都算"满足 10 部门各一套"**：3B 属中小负载——单卡即可"训得动"，档位只随部门**人数/数据量**定（标准档=多人排队不等待，轻量档=1~3 人小团队）；可验收指标=训练利用率不闲置、人不排队死等（估算）

引擎 B · 保密分区：三区十域

- **Z2 受控摆渡区**（唯一进出口）：外部数据/软件/权重 经白名单登记、杀毒、哈希校验、密级标识后**单向导入**
- **Z3 涉密训练区 = 10 个物理隔离封闭域**（每部门一套：训练机+数据+转换+烧录验证台，独立机柜/配电），彼此及对外**无网络连接**
- **Z4 监管区**：系统管理员 / 安全保密管理员 / 审计管理员 **三员分立**；日志只读镜像汇聚
- 模型/数据出区：**审批 + 密级标识 + 双人复核** → 装机交付；USB/光驱受控、禁私带介质

引擎 B · 成本与分期（估算待询价）

阶段	内容	一次性规模（估）
专项 POC	选 1 个部门跑通"3B 训—量—烧—验 + 保密分区落地"	¥150~250 万（一台训练机+数据台）
分批铺开	按两档铺 10 部门各一套	标准 ¥1500~2500 万 / 轻量 ¥600~1200 万
二期扩容	随型号需求 + 数据量实测	专项测算

- **人力增量：**训练算法 + 数据/验证 + 保密三员（估算 ¥150~250 万/年量级，另计）
- **配电/机房：**训练区独立分区/配电（10 套 IT ~60~80kW 量级），与在线推理分开评估
- **▶ POC 为何能验指标：**两门禁——"3B 装入 200I A2"（体积/时延/时序/功耗）只能真机测、"保密分区"只能实体三员/摆渡预检——均不可纯纸面推导，故先用 1 部门小 POC 换可验收数据

引擎 B · 风险与待确认

待确认/待实测：


#	项	影响
1	Atlas 200I A2 基础版 vs Ind 高可靠版 + 内存容量 (datasheet)	3B + 编码器能否装入
2	3B 装入模块实测 (权重大小/推理速度/时序/功耗)	方案成立性
3	保密办对部门密级界定 (可否同密级降级"分域分区")	布点与成本
4	训练整机/小机与配套单价 (询价)	成本转实测

主要风险：3B+编码器超模块 → 样机先导压测，必要时降编码器/INT4/蒸馏；图像/水声数据不足 → 先建 1 部门数据集；保密合规落地慢 → 保密办前置。

引擎 B · 与引擎 A 及公共底座的关系

- **独立采购**：训练卡 (910B 系) ≠ 推理卡 (300I A2) ， 两类清单分开
- **独立分区**：训练区涉密封闭域 (Z3) 与在线推理内网区物理隔离，不共用
- **数据底座 (C) 联动**：任务数据线 (图像/水声标注) 优先服务训练专项——C 区是训练区的"原料厂"
- **本期公共设施**：机房/电力按在线推理建，给训练区**留扩容口子但不作承诺**

统一推进节奏与风险（引擎 A+B 一体）



关键风险与缓解（指向 POC，不赌）〔01-\$7〕：

风险	缓解
硬件价格波动（±30%）	多源询价、POC 期锁价
KV-INT4 精度损失	POC 跑 SWE-bench 类基准；不达标退 INT8（+80 卡）
占空比/上下文分布偏差（卡数 ±20%）	POC 用 IDE 插件 + 会议日历采样两周实测校准
软件 offload 成熟度	A' 档不依赖 offload，B 档等成熟再演进
Flash-Next 昇腾软件栈适配（Qwen4 新架构算子 / EP-TP / KV 量化 / 1M；2026-08-26 才开源）	POC 首站以昇腾官方栈跑同基准；不达标退 KV INT8 或暂缓重负载扩卡，27B 多副本兜底
1M 冷加载首包 ~11s	仓库上下文预热 + 错峰准入

指标收口：A/B 三层验收总表 + 放行矩阵

收口规则：每个指标带 5 属性——目标 / 统计口径 / 测试条件 / 证据 / 不达标回退；A-在线按 P95 收口，B-机载按"平台级 + 任务级、额定工况最坏值"收口。

层	引擎 A · 在线	引擎 B · 机载	证据	不达标回退
业务体验	首包≤3s(P95-warm)；解码≥60(P95)；Agent 轮≤30s；报告排队≤10min	任务级：正确率≥现状基线 且 ≥上界 90%（生成 85%）【默认】；端到端时延按任务级 S1≤200ms/S2≤5s(上限15s)/S3 分钟级【默认】	真负载 / 固定回放集	预热、退 INT8、增数据/蒸馏
平台容量	占空比/上下文分布/报告频率实测（假设 15~35% 待校准）	3B INT4 体积≤模块可用内存；推理速度/时序/功耗	POC 两周采样 / 模块样机	按实测重算卡数（±20%）
采购放行	Flash-Next 昇腾栈达标（算子/KV/1M）	装得进+跑得动+精度达标，且保密预检三件证据（P50）	POC 验收门	退 INT8/暂缓扩卡/缩小试点

> 注：上表默认值均为【建议，待业务/保密办书面校准】；INT4 相对 BF16 量化退化 ≤2pp（分类类）为经验默认。在线 SLA 阶梯见 P13。

放行逻辑：POC 达标 → 提交正式采购（届时按"基准档 + 最大需求上界"两版）；部分达标 → 只扩试点或走"回退"列；主门禁（采购放行行）不达标 → 不采购、回方案层重审。

汇报收口：三句话 + 建议下一步

汇报要点（三句话）：

- 1. 企业 AI 基建 = **一份整体方案**：引擎 A·在线推理（本期落地） + 引擎 B·机载专用模型训练（POC 先行） + 数据底座 C——把"用 AI、造 AI、装 AI"的能力都沉淀在企业内部
- 2. 每一块的量都是从需求推出来的（A：96 卡，从人时漏斗；B：10 部门各一套，从机载模块反推）——预算可追溯、POC 先行再上量
- 3. 数据不出域 / 密级分区 / 权属自持——一次性投入买的是长期自持的能力

全口径一览（估算、待询价；B/C 本期不并表，是否并表交审议）：

构成	口径	金额（估）
引擎 A · 在线推理（本期）	CapEx / 年 OpEx	¥850~1100 万 / ¥110~160 万·年
引擎 B · 机载训练（POC 先行、独立立项）	1 部门 POC → 10 部门	POC ¥150~250 万 → 标准 ¥1500~2500 万 / 轻量 ¥600~1200 万
C · 数据与知识底座	存储/治理为主，随盘点立项	专项测算（P36）

> 注：两引擎共用公共设施（机房/电力/网络/存储/运维/安全）；引擎 B 与 A 的硬件、软件、密级分区相互独立（P46/P50/P53）。

正式采购 · 最大需求上界（参考，不构成本次批准）：

构成	上界场景	金额（估）
引擎 A · 在线推理	编码全员 1M 且 KV 全 HBM 硬上档	~200 卡，CapEx ¥1400~1600 万 [01-Q23]
引擎 B · 机载训练	10 部门全标准档（8×910B）	¥1650~2750 万（含 POC ¥150~250 万）
A+B 上界合计		≈ ¥3000~4400 万量级 （C 与人力另计）

> 注：上界仅用于锁预算边界与预留，**不是本次批准金额**。正式采购规模以 POC 实测 + 指标收口（P55）达标后的实际需求定档，届时按"基准档 + 最大需求上界"两版提交。

企业 AI 基础设施（依据 Q1 号研究报告）
本次请审议（供审议，非采购）：三项论证启动：

1. 启动引擎 A · 在线推理（第 POC 先行论证，¥150~250 万，2 个月）